东北大学 NORTHEASTERN UNIVERSITY

毕业设计（论文）

GRADUATION DESIGN (THESIS)

论文题目　基于模仿学习的机械臂抓取策略研究

学院名称　信息科学与工程学院

专业名称　自动化

学生姓名　高蕴喆

指导教师　李　智　教授

二〇二五年六月

学号 20215335 密级

东北大学本科毕业论文

基于模仿学习的机械臂抓取策略研究

学 院 名 称 ：信息科学与工程学院

专 业 名 称 ：自动化

学 生 姓 名 ：高蕴喆

指 导 教 师 ：李 智 教授

2025 年 6 月

Research on Robotic Arm Grasping Strategies Based on Imitation Learning

by Gao Yunzhe

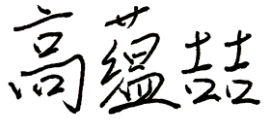
Supervisor: Professor Li Zhi

Northeastern University

June 2025

郑 重 声 明

本人呈交的学位论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料真实可靠。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确的方式标明。本学位论文的知识产权归属于培养单位。

本人签名：  日期：2025 年 5 月 29 日

摘 要

机械臂作为现代自动化领域的核心装备，已然成为带动各行业高效发展的核心动力，面对复杂多变的动态环境时，传统的抓取策略逐渐显露出自身的局限性，难以灵活适应快速更迭的工况，难以满足当下愈发多样化的任务需求。模仿学习赋予了机械臂从示教中掌握复杂操作技能的能力，切实降低了对精确建模和繁琐编程的依赖，相较于传统强化学习方法需要大量试错探索，模仿学习通过直接复用专家经验显著提升了数据效率，尤其是在机械臂这类高维连续控制场景。本论文旨在研究并验证基于模仿学习的机械臂抓取策略，重点探索了动作分块变换器（Action Chunking Transformer, ACT）算法在低成本硬件平台上实现高效、精细操作的潜力，ACT 算法通过动作分块预测、Transformer 序列建模、时间集成以及条件变分自编码器（CVAE），能有效处理高维连续动作并减小复合误差。ACT 算法创新性地将动作序列建模为离散分块，通过自注意力机制捕捉长距离时序依赖，解决了传统行为克隆方法中的误差累积问题。

本文依托开源的 Koch v1.1 六自由度机械臂构建了完整的自主控制系统，涉及硬件组装、电机配置校准、遥操作数据采集和策略训练部署，开展相关实证研究，成功实施并评估了两个典型操作任务：一是插头精确插入插座任务，证实了算法在高精度定位与装配方面的能力，实现了 86%的抓取成功率和 66%的插入成功率；二是快递流水线扫码与分拣任务，测试了算法在动态情境下处理多种物体的抓取、扫描与放置的综合水平，规则长方体的抓取成功率超过了 90%，并能准确完成后续操作。研究还将轻量级视觉网络和目标检测技术结合，对特定任务进行了优化操作。

本研究结果表明，ACT 算法结合低成本机械臂系统，可以有效学习并完成复杂的机械臂抓取及操作任务，在提高机械臂智能化水平与自主性、降低自动化门槛上展现出广阔的应用前景，为模仿学习技术在机械臂领域的实际应用积累了宝贵经验。

关键词：机械臂抓取；模仿学习；ACT 算法；自主控制系统

ABSTRACT

Robotic arms, central to modern automation, drive efficiency across industries, yet traditional grasping strategies struggle in complex, dynamic environments, failing to adapt to rapidly changing conditions and diverse task demands. Imitation learning enables robots to acquire complex skills from demonstrations, reducing reliance on precise modeling and complex programming. This thesis investigates and validates a grasping strategy based on imitation learning, focusing on the Action Chunking Transformer (ACT) algorithm's potential for efficient, robust manipulation on low-cost hardware. ACT leverages action chunk prediction, Transformer sequence modeling, temporal ensembling, and Conditional Variational Autoencoders (CVAE) to manage high-dimensional continuous actions and mitigate compounding errors.

An autonomous control system was developed using the open-source Koch v1.1 six-degree-of-freedom robotic arm, encompassing hardware assembly, motor calibration, teleoperation data collection (including multi-view images and joint states), and policy training/deployment. We successfully implemented and evaluated two representative manipulation tasks: First, the "precise plug insertion into a socket" task demonstrated the algorithm's capabilities in high-precision positioning and assembly. Second, the "express logistics conveyor belt scanning and sorting" task assessed the algorithm's comprehensive performance in dynamic grasping, scanning, and placing of multiple objects. Furthermore, the study integrated lightweight visual networks and object detection techniques to optimize operations for specific tasks.

Results show that ACT, paired with low-cost robotics, effectively handles complex grasping tasks, enhancing robot intelligence and autonomy while lowering automation barriers, offering valuable insights for practical imitation learning applications in robotics.

Key words: Robotic arm grasping; Imitation learning; ACT algorithm; Autonomous control system

目 录

摘 要 I

ABSTRACT II

1 绪论 1

1.1 研究背景 1

1.2 模仿学习及其在机械臂抓取中的应用现状 1

1.3 基于深度学习的模仿学习抓取策略研究 3

1.4 本文主要研究内容 4

2 基于模仿学习的动作分块变换器（ACT）算法 5

2.1 ACT 算法的基本原理 5

2.1.1 动作分块的理论基础 6

2.1.2 时间集成的平滑机制 6

2.1.3 条件变分自编码器的应用 7

2.2 ACT 算法的实现与架构 8

2.2.1 视觉骨干网络 8

2.2.2 变换器编码器-解码器 9

2.2.3 变分编码器 10

2.2.4 训练与推理 10

2.3 ACT 算法在抓取任务中的应用与性能 11

2.4 ACT 算法与其他控制方法的对比 12

2.4.1 与经典控制方法的对比 12

2.4.2 与其他模仿学习方法的对比 12

2.5 本章小结 13

3 基于模仿学习的遥操作单机械臂系统 15

3.1 机械臂硬件搭建 15

3.1.1 硬件组件 15

3.1.2 组装流程 16

3.2 电机配置与校准 17
3.2.1 电机初始配置 17
3.2.2 电机通信与控制 17
3.2.3 校准与遥操作准备 18
3.3 抓取分类任务建模与场景定义 20
3.4 遥操作与数据采集 20
3.4.1 遥操作实现 20
3.4.2 摄像头集成与环境感知 21
3.4.3 数据记录与存储优化 21
3.5 数据集的可视化与回放 22
3.5.1 数据集可视化 22
3.5.2 动作回放验证 23
3.6 策略训练与部署 24
3.6.1 神经网络策略训练 24
3.6.2 策略部署与实时推理 24
3.6.3 评估数据集的记录与可视化 25
3.7 数据采集的优化 25
3.7.1 数据一致性与任务设计 25
3.7.2 逐步引入数据多样性 25
3.7.3 记录过程中的优化技巧 26
3.8 本章小结 26
4 基于模仿学习的机械臂抓取任务与实验应用验证 27
4.1 插头插入插座任务 27
4.1.1 任务描述 27
4.1.2 数据采集与预处理 28
4.1.3 策略训练与优化 28
4.1.4 策略部署与评估 28
4.1.5 实际部署测试 29
4.2 快递与分拣任务 31

4.2.1 任务描述 31
4.2.2 数据采集与预处理 31
4.2.3 策略训练与优化 31
4.2.4 策略部署与评估 32
4.2.5 实际部署测试 32
4.3 实验结果总结 36
4.4 本章小结 38
5 结论 39
5.1 研究总结 39
5.2 研究展望 40
参考文献 41
致谢 45

1 绪论

1.1 研究背景

机械臂抓取是现代自动化技术中不可或缺的一环，其应用已拓展到制造业、仓储物流、医疗服务等多个领域，在复杂无常的应用场景范畴内，怎样让机械臂拥有高效、精准的抓取能力，始终是科研人员关注的焦点，传统的机械臂抓取策略一般是依赖精确的物理建模、精细的传感器数据和复杂的控制算法，应对未知环境、非结构化物体以及动态干扰的时候，表现出明显的局限，所以急需探索一种更具适应性和智能化的抓取方法，数据驱动的抓取合成方法通过分析物体特征和抓取策略，提供了更灵活的应对办法，为模仿学习的引入提供了基础保障[1]。

模仿学习（Imitation Learning, IL）是一种新兴的机器人学习方法，通过学习人类专家的示教数据，机械臂可凭借自身算法，自主完成抓取任务，为解决上述问题贡献了新思路[2]，与传统的强化学习方法相比，模仿学习不需要靠手动设计复杂的奖励函数，转而直接从示教数据中展开学习，这种方法降低了学习难度，加速了学习进程，推动了学习进展，尤其在进行抓取任务的时候，人类可以通过示教机械臂如何抓取不同类型的物体，使机械臂能迅速适应各类抓取场景。

但在复杂的物品抓取场景里，机械臂抓取依旧面临着高维连续动作的建模与规划的挑战，机械臂的动作空间往往是高维的，并且动作相互间存在复杂时序上的依赖关联，如何高效地表示和学习这些高维连续动作，是模仿学习在机械臂抓取领域面临的关键困境。近年来，随着深度学习技术的迅猛发展，基于深度学习的模仿学习方法在机械臂抓取领域取得了显著的进展[3]，特别是基于 Transformer 的动作分块算法，通过对动作序列进行建模，可以切实捕捉到动作间的时序依赖关系，提高抓取策略的性能[4]。

1.2 模仿学习及其在机械臂抓取中的应用现状

模仿学习也称为示教学习或学徒学习，是一种让智能体通过观察专家的示教数据，来学习并执行特定任务策略的学习范式，模仿学习的核心理念是将专家的行为模式导入到智能体上，使智能体能够像专家一样完成任务，相较于需要采用试错探索环境的强化学习，模仿学习借助专家的行为策略实现快速学习，避开了大量试错的阶段，降低了学习难度，增进了学习效率[2]。

根据学习方式的差异，模仿学习可以分为以下若干类别：

行为克隆（Behavioral Cloning, BC）是最简单的模仿学习方法，它把模仿学习问题转化成一个监督学习问题，通过学习一个映射关系，把状态映射到动作，再按照专家在特定状态时采取的动作，从而训练模型预测智能体在该状态下应当采取的动作[2]，Argall 等人采用行为克隆方法训练机械臂抓取各种形状的物体，通过直接学习人类的示教数据，机械臂能够迅速适应各种抓取任务[5]。行为克隆方法实现起来简单易行，但容易遭受分布偏移（Distribution Shift）问题的干扰，泛化水平较差，由于智能体在执行期间可能会遇到与示教数据不同的状态，所以在实际场景里，行为克隆方法容易因为出现错误累积造成性能下降。

数据集聚合（Dataset Aggregation, DAgger）是 Ross 等人了缓解行为克隆方法的分布偏移问题而提出的新方法，通过循环迭代收集智能体在既定策略下的数据，并把它和示教数据进行聚合处理，从而拓宽训练数据集的覆盖范围，拓展模型的泛化能力[6]。弗吉尼亚大学的相关学者采用改进后的 DAgger 算法，把扩散策略和 Dagger 进行结合，实现机器人操作任务的主动学习及不确定性估计，随后完成了机械臂的堆叠、推动和插拔等多种实际的操作任务[7]。DAgger 方法先采用行为克隆的方法训练一个初始策略，而后让智能体在环境中执行该策略，并将执行期间遇到的状态以及专家在该状态下应该采取的动作添加到训练数据集里，并不断重复上述环节，直到模型达成收敛，DAgger 方法在一定程度上缓解了分布偏移问题，但依然需要人工干预，成本较高。

逆强化学习（Inverse Reinforcement Learning, IRL）是一种借助专家行为学习奖励函数，之后采用强化学习算法进行学习的学习策略，Finn 等人利用最大熵逆强化学习算法，在人类示教数据里学习得到抓取奖励函数，同时利用强化学习算法对机械臂抓取策略进行训练[8]。和传统的强化学习方法不同，逆强化学习方法无需手动设计奖励函数，而是通过钻研专家行为背后的意图来习得奖励函数[9]，逆强化学习方法可以学习出稳定性佳且抗干扰的策略，然而其计算复杂度偏大。常用的逆强化学习算法包括最大熵逆强化学习（Maximum Entropy IRL）、结构化 SVM 逆强化学习（Structured SVM IRL）等[10]。

生成对抗模仿学习（Generative Adversarial Imitation Learning, GAIL）借鉴了生成对抗网络（GAN）的概念，运用对抗训练的方式去学习策略，GAIL 方法包含一个生成器（Generator）和一个判别器（Discriminator），生成器承担着生成与专家策略相似

的策略的职责，而判别器的任务则是区分生成器生成的策略和专家策略[11]，GAIL 方法可以学习到和专家策略近似的策略，但训练过程存在不稳定。近期，以扩散模型为基础的模仿学习方法通过生成多样化的动作序列，使得机械臂在复杂抓取任务里的泛化能力进一步增强[12]。

1.3 基于深度学习的模仿学习抓取策略研究

近年来，深度学习技术与模仿学习的结合的方法使机械臂抓取领域迈入了新阶段，深度学习模型强大的表征学习能力能让机械臂不用人工去设计复杂的特征，直接从原始的视觉信息及其他传感器数据中学习到抓取策略。

在基于视觉的抓取任务当中，研究者们广泛采用卷积神经网络（CNN）提取图像的相关特征，通过训练 CNN 网络让机械臂实现自动识别物体的功能，并提取出与抓取相关的特征信息数据，诸如物体的位置、形状、姿态等，随后把这些特征信息输入到模仿学习模型当中，预测机械臂的抓取动作。Lenz 等人借助 CNN 从 RGB-D 图像里提取物体特征，随后训练相应的行为克隆模型，最终成功完成了在复杂环境中抓取物体的任务[13]，该方法摆脱了对传统图像处理算法的依赖，使得机械臂能更顺利地适应各类光照条件和背景干扰，凭借大规模数据采集，深度学习能明显提高机械臂的手眼协调的能力，进而实现更鲁棒的抓取策略[14]。

除了固定的静态图像信息外，机械臂抓取任务一般还包含一系列连贯的动作，为了捕捉动作彼此间的时序依赖关系，研究者们开始尝试采用循环神经网络（RNN）以及 Transformer 等序列模型。RNN 及其变体（LSTM、GRU）可有效地处理时序数据，学习到动作序列中的长期依赖关系，Du 等人采用 LSTM 网络对机械臂的动作序列进行建模，通过让机械臂观察人类抓取动态物体的过程，学习怎样预测物体的运动轨迹，进而依据轨迹调整抓取的动作，这样便稳定可靠地实现了抓取动态物体的任务[15]。

近年来，Transformer 模型鉴于其强大的自注意力机制，在自然语言处理领域取得了巨大的成功，并且也开始应用到机械臂抓取任务中，Transformer 模型可捕捉序列中的长距离依赖关系，并且有并行计算的优点，可以提高学习的效率。Tony Z. Zhao 等研究者在他们的工作里研发出 ACT 算法，该算法通过 Transformer 模型对机械臂的动作序列加以建模[4]，ACT 算法把连续的动作序列分解成一系列离散的动作块，接着利用 Transformer 模型对这些动作块实施建模操作，靠这种方式，ACT 算法能有效地把我动作之间的时序关系，提高抓取策略的性能，实验结果表明，ACT 算法在多个精细

操作任务里实现了显著的性能提升。

1.4 本文主要研究内容

针对上述挑战，本文使用了基于动作分块变换器（Action Chunking Transformer, ACT）算法的机械臂抓取策略，借助低成本的 Koch v1.1 六自由度机械臂平台，探索高效、坚实的抓取与操作方法。ACT 算法通过动作分块预测、Transformer 序列建模、时间集成以及条件变分自编码器（CVAE），有效降低复合误差、提升动作平滑性，并且增强了对高维连续动作以及多模态示教数据的建模水平。本研究通过构建完整的自主控制系统，验证了 ACT 算法在低成本硬件上的应用潜力，并在插头精确插入插座任务和模拟快递流水线动态扫码分拣任务中进行了实证评估。

本论文各章节的内容结构如下：

第 1 章主要讲述了机械臂抓取的研究背景、模仿学习的理论基础及当前困境，引出本文的研究目标。

第 2 章主要介绍了 ACT 算法的原理、架构以及与传统方法的对比，展现 ACT 在高精度抓取任务中的优势。

第 3 章主要描述了从硬件组装、电机配置、数据采集到策略训练与部署的完整流程，展现低成本平台相关的实现细节。

第 4 章以插头插入插座和快递流水线分拣扫码两个任务为核心，对数据采集、训练优化和实际测试结果进行分析，并与传统方法对比。

第 5 章总结了本文的研究成果，对 ACT 算法和 Koch v1.1 平台性能进行分析，展望未来的改进方向。

2 基于模仿学习的动作分块变换器（ACT）算法

本章系统探讨了动作分块变换器（Action Chunking Transformer, ACT）算法在基于模仿学习的机械臂抓取策略中的核心意义，ACT 算法采用动作分块预测、Transformer 序列建模、时间集成以及条件变分自编码器（CVAE）的手段，切实应对高维连续动作建模的挑战，明显增强了复杂抓取任务的精度与鲁棒性。与传统控制方法比起来，ACT 凭借端到端的学习模式，能直接从人类示教数据里提取动作模式，降低了对复杂环境建模的依赖，特别适用于低成本硬件平台开展的精细操作任务[16]，本章将详细阐释 ACT 算法的原理、架构及其在机械臂控制中的应用优势，同时与其他控制方法进行对比，展现其在模仿学习领域的创新特质。

2.1 ACT 算法的基本原理

动作分块变换器（Action Chunking with Transformers，简称 ACT）是一种专门针对机器人精细操作任务设计的模仿学习算法，其核心思想是参考神经科学中的“动作分块”概念，即把一系列动作序列作为一个整体单元进行处理和执行，以此来提高效率并减少错误累积[17]。ACT 算法通过预测未来多个时间步的动作序列，而非仅仅单一时间步的动作，大幅降低了任务的有效时间跨度，从而减轻了模仿学习中普遍存在的“复合误差”问题，特别适适合有高精度、闭环视觉反馈和双臂协调需求的场景[4]。

ACT 算法采用了一种基于变换器（Transformer）的架构，利用其在序列建模方面的优势来处理高维输入（如 RGB 图像和机械臂关节状态）与动作序列之间的复杂映射关系，采用“动作分块”策略，将未来的 k 个时间步的动作作为一个整体预测，缩短了任务的预测时间跨度，还能更好地捕捉演示数据中的非马尔可夫行为，如人类操作中的暂停或节奏变化；而且为了增强动作序列的平滑程度，引入了时间集成（Temporal Ensembling）机制，通过对存在重叠的动作分块进行加权平均，生成更平滑的动作轨迹；ACT 同时还采用了条件变分自编码器（Conditional Variational Autoencoder，CVAE）的训练框架，从而更好地对人类演示数据中的噪声和多模态特性建模[4]。

在实际场景的实践中，ACT 算法接收当前的环境观测数据（包括来自多个摄像头的 RGB 图像和机械臂关节位置），生成未来 k 个时间步的动作序列（通常为目标关节位置）并让低级 PID 控制器跟踪执行，借此实现高频控制（通常为 50Hz），从而使 ACT 在低成本硬件上实现高精度的双臂操作，如完成打开透明调味杯或插入电池等

任务[4]。

2.1.1 动作分块的理论基础

动作分块的概念源于心理学和神经科学，描述了人类怎样把一系列动作组织成一个整体单元以提高执行效率，而在机器人控制这一学科范畴内，这一概念被转化为对未来k个时间步的动作序列的预测，而不是传统的单步预测，不妨假设任务的总时间步为T，传统的单步预测需要T次决策，而 ACT 通过预测k步的动作分块，将决策次数减少到T/k次，减少了错误累积的次数，明显降低了复合误差的影响力度[17]。

动作分块变换器 ACT 通过预测固定时间步长（chunk size）的动作序列来实现机器人控制的平滑性与高效性。给定当前观测o_t（如 RGB 图像）和机械臂状态s_t（如关节位置），ACT 模型预测未来k步的动作序列$\hat{a}_{1:k}$。其数学表达为：

$$\hat{a}_{1:k} = f_{\mathrm{ACT}}(o_t, s_t; \theta), \quad \hat{a}_{1:k} \in \mathbb{R}^{k \times d_a} \tag{2.1}$$

其中，$\hat{a}_{1:k}$表示预测的动作序列，维度为$k \times d_a$，d_a为动作维度（如 Koch v1.1 机械臂的 6 维动作空间），f_{ACT}为 ACT 模型，参数为θ。该模型通过条件变分自编码器（CVAE）和 Transformer 架构实现动作预测。

在模仿学习中，尤其是针对高精度任务而言，复合误差一直是颇为棘手的挑战，传统的行为克隆方法在预测单一动作的时候，极易因小误差的不断累积，造成机械臂偏离训练分布，导致陷入难以恢复的状态，而 ACT 算法可借助预测动作序列，缩短任务的有效时间跨度，以此降低误差累积的几率[1,3]。动作分块的概念还与分层动作分解相关，通过将复杂任务分解为子序列，提升了高维动作空间中的学习稳定性[18]。动作分块还在处理人类演示数据中的非马尔可夫行为上起到一定作用，人类在操作过程中因犹豫或调整而暂停之类的行为难以通过单步预测的马尔可夫模型捕捉，而 ACT 算法可以通过预测整个动作序列来更好地建模这些时间相关的行为模式。

2.1.2 时间集成的平滑机制

为了避免因每k步时突然引入新观测造成的动作不连续，ACT 引入了时间集成机制，在每个时间步都会查询策略，生成新的动作分块，这些分块在时间上存在重叠，同一时间步可能会有多个预测动作；时间集成机制通过对这些重叠动作进行加权平均来生成最终的动作输出，其权重采用指数衰减形式：

$$w_i = \frac{e^{(-m \cdot i)}}{\sum_{j=0}^{k-1} e^{(-m \cdot j)}}, \quad i = 0, 1, \ldots, k-1 \tag{2.2}$$

其中，w_i为第i个动作的权重，m为时间集成系数，其大小决定了新观测的融入

速度，m越小更新越快，而较大的m则会更多地保留历史动作的影响，这里m通常设为 0.1，　k为动作分块长度，Koch v1.1 中$k=16$。归一化使$\sum_{i=0}^{k-1} w_i = 1$，确保各时间步贡献均衡，保证动作平滑性，避免动作突变。

时间集成的优势在于它能够在保持动作精度的同时显著提高动作的平滑性，传统的动作分块可能因观测的突然切换导致机械臂动作出现抖动，而时间集成通过平滑过渡减少了这种不连续性，不仅提高了任务执行的稳定性，还可以减少机械臂硬件的磨损，所以在实际应用中这种机制显得尤为重要[19]。

2.1.3 条件变分自编码器的应用

ACT 采用 CVAE 作为训练框架，以应对人类演示数据的噪声和多模态特性。人类演示通常具有随机性，例如在相同的观测下可能采用不同的动作序列，CVAE 通过引入一个潜变量z来建模这种多模态性，训练时 CVAE 编码器根据当前的关节位置和目标动作序列预测z的分布（通常为对角高斯分布），而解码器（即策略）则根据z和当前观测生成动作序列；测试时，z从先验分布（标准正态分布）中采样，或取编码器预测的均值，以平衡确定性与多样性[4]。CVAE 训练流程如图 2.1 所示。

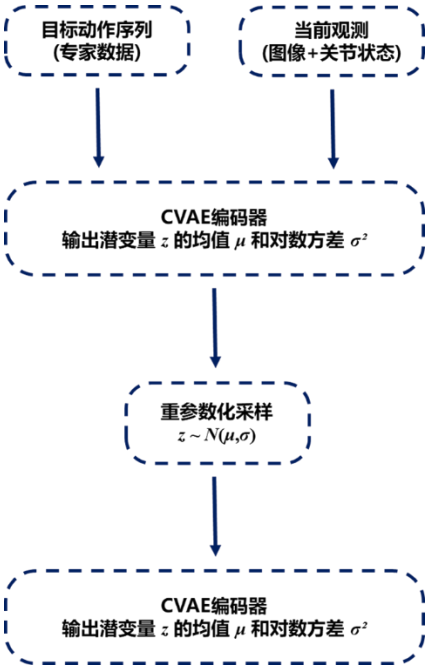


图 2.1 CVAE 训练流程

CVAE 的训练目标包括两部分：重构损失（确保预测动作接近目标动作）和正则化项（使编码器的输出分布接近标准正态分布）。总损失函数为：

$$\mathcal{L}_{\text{CVAE}} = \mathcal{L}_{\text{recon}} + \beta \cdot \mathcal{L}_{\text{KLD}} \tag{2.3}$$

其中，重构损失为：

$$\mathcal{L}_{\text{recon}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{t=1}^{k} \| \hat{a}_{i,t} - a_{i,t} \|_1 \tag{2.4}$$

正则化项通过 KL 散度实现，KL 散度损失为：

$$\mathcal{L}_{\text{KLD}} = \frac{1}{N}\sum_{i=1}^{N}\left[-\frac{1}{2}\sum_{j=1}^{L}\left(1+\log(\sigma_{i,j}^2) - \mu_{i,j}^2 - \sigma_{i,j}^2\right) \right] \tag{2.5}$$

其中，$\hat{a}_{i,t}$ 和 $a_{i,t}$ 分别为第 i 个样本在时间步 t 的预测动作和目标动作，k 为动作分块长度，$\mu_{i,j}$ 和 $\sigma_{i,j}^2$ 为潜变量 z 的均值和方差，L 为潜在维度，β 为 KL 散度权重，过高的 β (>0.1)会减少 z 传递的信息量，从而迫使解码器更多地依赖观测数据，导致动作模式坍缩，经网格搜索验证，$\beta = 0.01$ 在 ALOHA 平台上能够平衡重构精度与潜在空间多样性。CVAE 的这种设计使得 ACT 能够聚焦于需要高精度的动作区域，同时容忍无关区域的随机性[3]。变分自编码器在模仿学习中的应用进一步增强了对多模态示教数据的建模能力，特别是在处理噪声数据时表现出鲁棒性[20]。

2.2 ACT 算法的实现与架构

ACT 的实现基于变换器架构，结合了视觉处理、序列建模和动作预测的功能，其整体架构可以分为三个主要部分：视觉骨干网络、变换器编码器-解码器，以及动作回归头，当使用 CVAE 训练时，还额外包括一个独立的变分编码器[4]。ACT 的算法架构如图 2.2 所示。

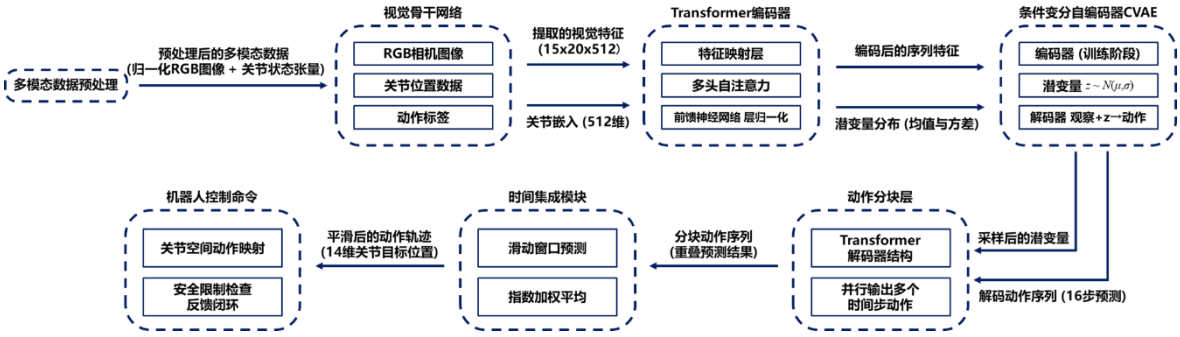


图 2.2 ACT 算法架构

2.2.1 视觉骨干网络

ACT 的输入包括来自两个摄像头的分辨率为 480×640 的 RGB 图像和机械臂的关节位置。为了处理图像数据，ACT 采用 ResNet18 作为视觉骨干网络，将每个图像转换为 15×20×512 的特征图。特征提取过程表示为：

$$F_{\text{img}} = \text{ResNet18}(I;\theta_{\text{backbone}}),\quad F_{\text{img}} \in \mathbb{R}^{B\times C\times H\times W} \tag{2.6}$$

其中，$I \in \mathbb{R}^{B\times N_c\times 3\times H_{\text{in}}\times W_{\text{in}}}$ 为输入图像，B 为批次大小，N_c 为摄像头数量（例如 2,3,4），F_{img} 为特征图（例如 15×20×512）。

接下来，将这些特征图展平为 300×512 的序列，再添加二维正弦位置嵌入以保留空间信息，并将四个摄像头的特征序列被拼接成 1200×512 的输入序列，作为变换器编码器的其中一个输入 [4]。轻量级卷积网络的进步为资源受限平台的视觉处理提供了优化方案，进一步提升了 ACT 的计算效率[21]。

关节位置则是通过线性层投影到与特征序列相同的嵌入维度（512 维），并与图像特征一起作为变换器编码器的输入。这种设计允许 ACT 同时处理高维视觉信息和低维状态信息，实现闭环视觉反馈控制。

2.2.2 变换器编码器-解码器

ACT 的 Transformer 架构包括编码器和解码器，其中编码器接收来自视觉骨干网络的图像特征、关节位置以及潜变量 z（在测试时为零向量）等输入，将其投影到统一的嵌入维度，并添加一维和二维位置嵌入以保留序列和空间信息，通过多头自注意力机制处理输入序列。注意力机制表示为：

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.7}$$

其中，$Q,K,V \in \mathbb{R}^{S\times d_m}$ 分别为查询、键和值矩阵，S 为序列长度，d_m 为模型维度，$d_k = d_m/h$，h 为注意力头数。解码器通过交叉注意力将编码器输出作为键和值，查询来自动作序列。

ACT 采用一维和二维正弦位置编码来保留序列和图像的空间信息，其中图像特征添加二维正弦位置编码以保留空间位置，关节状态和动作序列添加一维位置编码以标记时序顺序。一维位置编码为：

$$\begin{aligned}\text{PE}_{1D}(p,2i) &= \sin\left(\frac{p}{10000^{2i/d_m}}\right)\\ \text{PE}_{1D}(p,2i+1) &= \cos\left(\frac{p}{10000^{2i/d_m}}\right)\end{aligned} \tag{2.8}$$

二维位置编码为：

$$\begin{aligned}\mathrm{PE}_{2D}(x,y,2i)&=\sin\left(\frac{x}{W}\cdot 2\pi\cdot\frac{1}{10000^{2i/d_m}}\right)\\ \mathrm{PE}_{2D}(x,y,2i+1)&=\cos\left(\frac{y}{H}\cdot 2\pi\cdot\frac{1}{10000^{2i/d_m}}\right)\end{aligned}\tag{2.9}$$

其中，p 为序列位置，(x,y) 为特征图坐标，H 和 W 为特征图高度和宽度。编码器通过多头自注意力机制和前馈神经网络处理这些输入，生成一个综合的特征表示[4]。基于注意力的序列建模在机械臂动作预测中表现出色，能够有效捕捉长距离依赖关系，提升动作序列的连贯性[22]。

解码器的输入则是一个固定的 $k\times 512$ 位置嵌入序列，表示未来 k 个时间步。解码器通过交叉注意力机制与编码器的输出交互，生成 $k\times 512$ 的特征序列，这些特征随后通过动作回归头（Action Regression Head）映射到机械臂动作空间。回归头由两层全连接网络构成，第一层将 512 维特征压缩至 256 维并施加 ReLU 激活和层归一化，第二层进一步投影至 6 维动作空间来对应双臂关节位置，最终输出 $k\times 6$ 的动作序列，由低级 PID 控制器跟踪执行。

变换器的设计充分借鉴了自然语言处理和目标检测领域的技术，编码器采用类似 BERT 的结构，而解码器输入为可学习的 k 个查询向量（类似 DETR），借助交叉注意力与编码器特征交互[23, 24]。这种设计使 ACT 能够高效地处理长序列输入，并生成连贯的动作序列。

2.2.3 变分编码器

在 CVAE 训练模式下，ACT 架构中包含一个独立的变分编码器，用来推断潜变量 z 的分布。编码器接收当前关节位置和目标动作序列，输入序列是由一个可学习的[CLS]标记、投影后的关节位置和动作序列组成，而编码器输出[CLS]标记对应的特征，借助线性层投影到 $2\times L$ 维空间（L 为潜在维度），分别表示 z 的均值和对数方差。采样时采用重参数化技巧，以确保梯度可回传[4]。

在测试时，可将变分编码器丢弃，并将潜变量 z 设置为零向量，这样可以简化推理过程，同时保证动作输出的确定性。

2.2.4 训练与推理

ACT 的训练过程首先是从演示数据集中采样观测（图像和关节位置）和对应的动作序列，接下来通过变分编码器推断 z 的分布并采样，再使用解码器预测动作序列，并计算重构损失和 KL 散度损失。训练采用 Adam 优化器，模型总参数量约 6200 万，其中 ResNet18 占 11.7M，Transformer 编码器-解码器占 48M，CVAE 相关模块占 2.3M，

训练时间在单个 RTX 4060 Ti GPU 上约为 6 小时。高效的训练策略，如混合精度训练，可进一步降低计算成本，同时保持模型性能[25]。

在推理阶段，ACT 每秒查询 50 次（对应 50Hz 控制频率），生成k个时间步的动作序列，当前时间步的动作可通过时间集成机制，由多个重叠分块的预测加权平均得到，推理时间约为 0.01 秒，满足实时控制的需求。推理时，ACT 通过时间集成机制生成平滑的动作序列，以适应机器人控制的实时性要求。动作更新公式如下：

$$a_t = \sum_{i=0}^{k-1} w_i \cdot \hat{a}_{t,i} \tag{2.10}$$

其中，a_t为时间t的最终动作输出，$\hat{a}_{t,i}$为第i个动作分块的预测动作，$m = 0.1$，权重w_i与公式（2.2）一致，确保动作序列的平滑性。

2.3 ACT 算法在抓取任务中的应用与性能

ACT 算法在多个精细操作任务里表现出色，尤其是在低成本硬件平台 ALOHA 上，ALOHA 是一个基于 ViperX 和 WidowX 机械臂的双臂遥操作系统，成本约为 2 万美元，远低于传统高精度机器人系统，ACT 在该平台上成功完成了六项现实生活中的任务的学习，分别是拉上拉链袋、插入电池、打开调味杯盖、穿入魔术贴的线、准备胶带和穿鞋，这些任务虽属于日常生活中的简单事务，但当用机械臂去做这些任务的时候，依然需要有高精度的双臂协调运作、闭环视觉反馈和对复杂物体（例如透明或低对比度的物体）的处理操作[4]。

以打开调味杯任务为例，该任务需要机械臂将杯子翻倒，然后推入左臂夹爪，随后轻轻夹紧并抬起杯子，之后用右臂去撬开杯盖，ACT 在这项任务中实现了 84%的成功率，远超其余模仿学习方法的表现。而在另一个给设备插入电池的任务里，ACT 能达到 96%的成功率，可精准地将电池放入遥控器插槽里，同时用左臂稳定住遥控器，进而应对插入时出现的弹簧阻力，ACT 的动作分块与时间集成机制可有效降低动作抖动，提升执行稳定性，这些任务的成功率明显提高[4]，在类似的高精度任务情境中，Transformer 模型在处理复杂视觉输入时也展现出优越的鲁棒性[26]。

在模拟环境中，ACT 也在立方体传递和双臂插入两项任务中表现出出色水平，分别实现了 86%和 32%（人类演示数据）的成功率，而诸如 BC-ConvMLP、BeT、RT-1 和 VINN 的传统模仿学习方法，在这些任务里成功率大多低于 30%，特别是在对高精度与复杂协调有要求的子任务中表现欠佳[9,27-29]，对于这些任务，ACT 性能出色是

因为它拥有缓解复合误差以及对非马尔可夫行为建模的能力。

ACT 在应对感知挑战方面也展现出优秀的性能，拉上拉链袋任务涉及到透明的拉链袋和低对比度背景，传统的依赖深度相机的系统难以精确感知，而 ACT 直接从 RGB 图像中学习动作映射，绕过了复杂的物理建模的需要，展现出其在复杂环境中的稳定性[4]。

2.4 ACT 算法与其他控制方法的对比

2.4.1 与经典控制方法的对比

经典的机械臂控制方法，如基于模型的运动规划与控制，一般需要依赖精准的环境动态模型与状态估计，早期的双臂操作研究在设计控制器时要借助已知的动态模型，但这种方法在应对具有复杂物理特性的物体（如柔性或透明物体）时，需要大量针对特定任务的工程工作[30]，ACT 依靠端到端的学习策略，直接把 RGB 图像以及关节位置映射到动作，省去了复杂的建模过程[4]，这种从像素到动作的范式特别契合精细操作任务，它允许策略根据视觉反馈实时进行调整，而不需要精准预判物体的运动轨迹。

经典方法实现状态估计一般需要高精度的硬件和传感器，需要昂贵的高分辨率深度相机或力传感器，而 ACT 仅依赖普通网络摄像头以及关节编码器，就能够在低成本的 ALOHA 系统里面运行，因为这种硬件友好性，ACT 能更顺利地推广到资源有限的实验室，还有工厂和家庭这类实际应用场景中。

2.4.2 与其他模仿学习方法的对比

ACT 和传统的模仿学习方法（行为克隆、BeT、RT-1 和 VINN）相对比，在精细操作任务里表现更为出色，行为克隆借助卷积网络对图像加以处理并预测单一动作，在任务期间，尤其是在长序列任务期间，极易受到复合误差的影响 [1,31]。BeT 和 RT-1 虽同样采用变换器架构，但它们预测的结果为单一动作，还需凭借历史观测或离散动作空间，损害了它们在高精度任务中的表现[27,28]。VINN 是一种非参数方法，采用检索最接近的演示动作来生成动作，然而在应对高维视觉输入和复杂任务时，VINN 的性能表现不佳[29]。

ACT 通过动作分块显著降低了任务的有效时间跨度，缓解了复合误差的影响；时间集成机制提升了动作的平滑性，填补了传统方法在动作连续性方面的缺陷；CVAE 训练框架进一步强化了 ACT 对人类演示数据中噪声与多模态性的建模能力，使其能够更高效地捕捉关键动作模式，在进行拉上拉链袋任务期间，ACT 实现了 88%的成

功率，而其他方法在初始抓取阶段后的成功率接近零[4]。

2.5 本章小结

动作分块变换器（ACT）算法将动作分块、时间集成和 CVAE 训练框架相结合，为低成本硬件上的精细操作任务提供了一种高效的模仿学习解决方法[4]，其基于变换器的架构可以对高维视觉输入和复杂动作序列加以处理，有效减轻了复合误差现象，并在多个真实世界以及模拟任务中收获了出色的表现。与经典控制方法相比，ACT 无需进行复杂的环境建模，适合去处理具有复杂物理特性的物体；与其他的模仿学习方法相比，ACT 采取动作分块和时间集成的做法，提高了动作的精度和平滑性，但受硬件能力与感知挑战的局限，在一些极端任务里，ACT 算法需要更多的训练数据或者优化后的感知系统。ACT 是一种在低成本平台上实现高精度机械臂操作的创新方法，为未来的机械臂研究和实际应用提供了重要的参考。

3 基于模仿学习的遥操作单机械臂系统

本章详细剖析了基于模仿学习构建机械臂自主控制系统的完整流程，从硬件搭建、电机调试、数据采集到策略训练与部署，该控制系统设计呈现出通用性，可适配各种机械臂硬件平台，采用灵活的配置和模块化设计法，可在不同的机械臂架构上高效实现抓取与操作工作。本章以开源的 Koch v1.1 六自由度机械臂为例，展现了系统在低成本硬件上的实现细节与性能表现。通过遥操作、数据采集以及神经网络训练等举措，系统可以完成复杂抓取任务，并且具有跨设备迁移的能力，为中小型实验室、家庭场景与工业场景提供了经济又实用的解决方案，实验呈现出较强的通用特性，对配置进行调整即可适配其他机械臂平台，如 ALOHA 机械臂、SO-ARM100 机械臂等。

3.1 机械臂硬件搭建

3.1.1 硬件组件

Koch v1.1 机械臂是一种经济实用的开源机械臂平台，设有一个主臂（leader arm）和一个从臂（follower arm），各臂均配备 6 个 Dynamixel 电机，适用于需要精确控制以及视觉感知的作业，如物体抓取和放置。Koch v1.1 机械臂硬件组件如图 3.1 所示。



图 3.1 Koch v1.1 机械臂硬件组件

主臂和从臂的电机配置有所区别，主臂的 6 台电机采用的型号均是 XL330-M077，其具备最大扭矩 0.52 Nm 的高扭矩密度，可适应主臂作为操作者控制接口时对高精度

和快速响应的要求，同时 5V 的低功耗便于统一电源管理，降低系统的复杂程度。从臂的肩部平移和抬升关节选用两台最大扭矩 1.4 Nm，12V 电源的 XL430-W250 型号电机，其更大的扭矩可支持从臂执行抓取和搬运任务时的负载需求；另外四台用于肘部、腕部和夹爪的 XL330-M288 型号电机，最大扭矩 0.39 Nm，使用 5V 电源，其较轻的负载需求以及与主臂电机的兼容性，有助于达成主从臂动作同步，同时实现成本效益最大化，Koch v1.1 机械臂是一款采用模块化设计的开源机械臂，模块化设计思路可以增强系统的可维护性以及扩展性，如今在机械臂组装中已被广泛采用[32]。图 3.2 呈现的是 Koch v1.1 机械臂电机布局配置示意图。

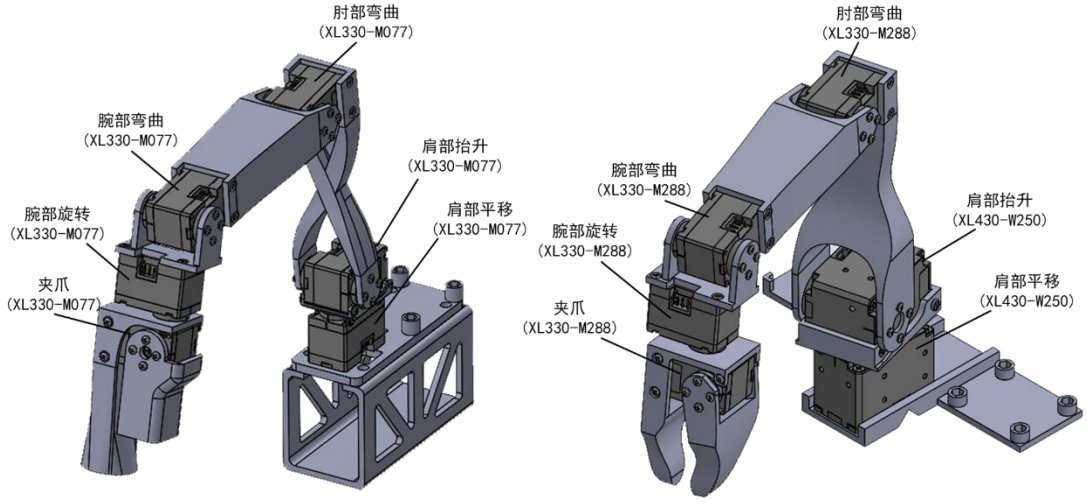


图 3.2 Koch v1.1 机械臂电机布局配置示意图

3.1.2 组装流程

组装 Koch v1.1 机械臂需要依照官方提供的说明逐步完成，从底盘固定操作到电机安装，再到电线连接，每一步都需要精准的操作，主臂作为操作者实施控制的接口，承担起接收输入动作的工作；从臂则需要通过模仿主臂的动作去执行任务。

在组装时要特别留意电源线的连接，主臂上的电机全部连接到 5V 电源总线，而从臂的电机则需要连接 12V 电源，然后将电源连接至电压转换器，以适配 5V 电机的需求，任何接线错误都可能造成电机无法工作，甚至引起电机损坏，机械臂通过 USB 与计算机相连接，但 USB 仅用于数据传输，不能代替电源使用，故而必须保证主从两臂的电源线正确连接且通电，否则计算机将无法检测到机械臂硬件，组装工作完成后，需要进行初步检验测试，查看各部件是否牢固、电机是否可自由旋转，避免后续配置中出现差错。

3.2 电机配置与校准

3.2.1 电机初始配置

待硬件组装完毕后，需要对 Koch v1.1 机械臂的电机进行初始配置，以保证其能正常通信且正常运行，鉴于机械臂使用的是 Dynamixel 电机，孤儿要先安装相关依赖库以维持电机通信，用户可依据开发环境，从 pip、poetry 或 uv 等工具中选择进行安装，安装完成后，需要给每台电机分配唯一的 ID，以避免出现通信冲突。

Koch v1.1 的主臂和从臂各有 6 个电机，配置过程从主臂开始，因其电机型号一致（均为 XL330-M288），操作相对容易，需先把全部电机连接断开，接着依次去连接各台电机，并使用 configure_motor.py 脚本为其设置 ID，把第一台电机的 ID 设置为 1，第二台设置为 2，直到第六台电机 ID 设为 6。从臂的配置过程则稍显复杂，配置电机时，一定要确保两种电机的电源电压和电机型号相匹配，否则电机就会有烧毁的可能。

完成 ID 分配这一工作后，所有电机以菊花链方式进行连接，也就是用单条总线串联，维持信号传输的稳定状态，配置完成以后，需要运行端口检测脚本，获取主臂和从臂的 USB 端口号，从而检验连接是否正确，在 Ubuntu 20.04 系统中，端口为 /dev/ttyACM0 和/dev/ttyACM1。

3.2.2 电机通信与控制

实时控制时，电机通信的稳定性至关重要，尤其是在高频控制这类场景里面，需确保数据传输拥有低延迟和高可靠性[33]，电机配置完成后，需要采用 DynamixelMotorsBus 类与电机建立通信，DynamixelMotorsBus 类基于 Dynamixel SDK 实现，具备一系列读取和写入电机数据的接口。初始化时，需要为每条机械臂创建 DynamixelMotorsBus 实例，且要指定相应的 USB 端口及电机配置，主臂和从臂的电机各自命名为肩部平移、肩部抬升、肘部弯曲、腕部弯曲、腕部旋转和夹爪，并给每台电机配置好对应的索引和型号。电机索引需要与前面配置的电机 ID 相适配，如主臂的肩部平移电机索引需设置为 1，型号为 XL330-M077；从臂的肩部平移电机索引设为 1，型号为 XL430-W250；从臂的夹爪电机索引设为 6，型号为 XL330-M288。主从臂电机均需配置波特率为 1Mbps，与 Dynamixel SDK 默认参数一致，确保与 Koch v1.1 官方配置兼容。

Koch v1.1 采用 Dynamixel 协议实现电机控制，把 ACT 预测的动作序列转化成对应的电机指令，控制信号借助 PID 控制器生成，公式如下：

$$u_t = K_p(\theta_{\text{target},t} - \theta_{\text{current},t}) + K_d\dot{\theta}_{\text{current},t} \quad (3.1)$$

其中，u_t 为时间 t 的控制信号（扭矩），$\theta_{\text{target},t}$ 和 $\theta_{\text{current},t}$ 分别为目标位置和当前位置，$\dot{\theta}_{\text{current},t}$ 为当前角速度，K_p 和 K_d 分别为比例增益和微分增益。

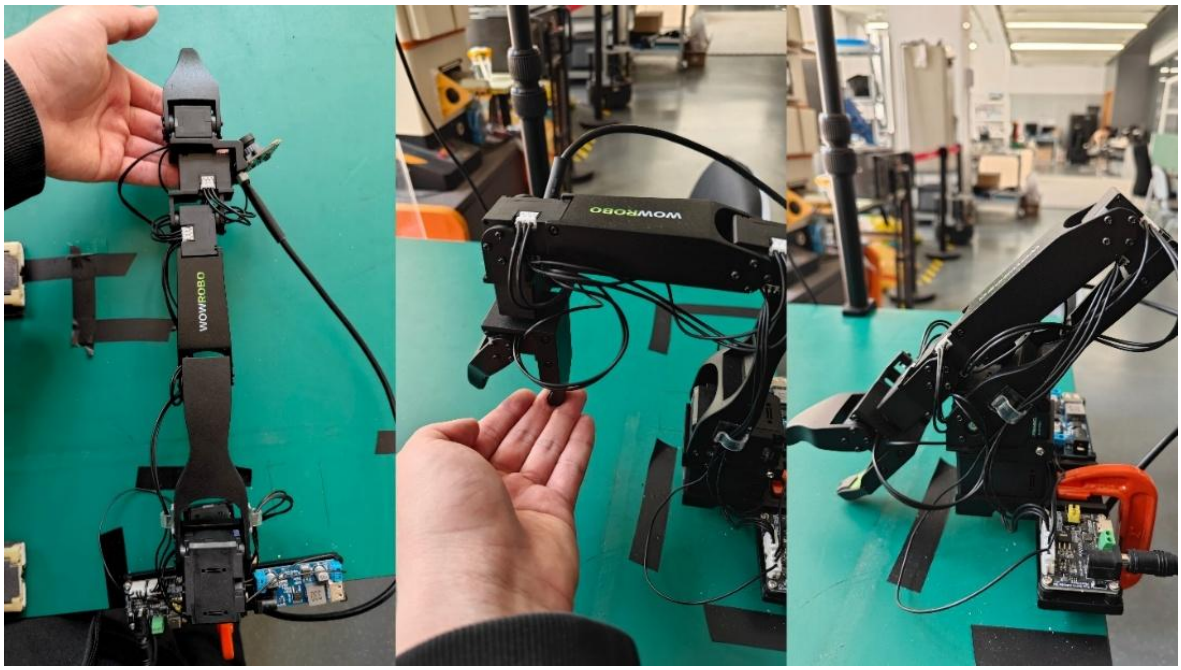
首次连接电机时，需运行 leader_arm.connect()和 follower_arm.connect()，此时系统会检测电机索引是否与配置一致。若与配置中的 1 到 6 不匹配，则会触发配置程序，此时需要依次断开和连接电机电源，并按照提示完成索引设置。配置过程中，需特别注意电源的插拔顺序，确保从总线最近的电机开始逐一配置。配置完成后，电机索引将被保存到其持久内存中，后续无需再次配置。

完成配置后需用 Dynamixel Wizard 工具检查所有 12 台电机的 ID 和波特率（通常设成 1Mbps）是否正确无误，检查期间需要逐一选择电机并挪动机械臂，观察软件界面上的图形指示器是否反映实际的运动情形，电机控制系统的鲁棒性对实现动作精度起到关键作用，尤其是在复杂任务场景中[34]。

连接成功后，可以通过读取、写入指令对电机功能开展测试，如读取主臂和从臂的当前位置，观察数值如何随手臂移动而变化；或者激活从臂的扭矩，使其固定在当前位置，同时借助写入指令调整电机的位置，如把肩部平移电机的位置增加 10 个单位，或把夹爪位置调整 30 个单位。需要留意的是，若电机启用了扭矩，就不可以手动移动，否则可能造成机械损坏，如确需手动移动，则应断开程序及电源，随后再进行操作，Dynamixel 电机若高负载运行或长时间工作就容易过热，故使用后需及时断电冷却，延长电机寿命。

3.2.3 校准与遥操作准备

为保证主臂和从臂处于相同物理位置时位置值一致，需要使用 ManipulatorRobot 类对机械臂进行校准，ManipulatorRobot 类封装了机械臂控制的核心功能，涵盖了电机通信、校准以及遥操作。校准时，系统会检查.cache/calibration/koch 目录下是否缺失校准文件，若缺少校准文件，就会启动校准程序，要求用户将主臂与从臂分别移动到三个指定位置：零点位置、旋转位置和休息位置。零点位置用来计算电机的初始偏移数值，以明确电机自出厂以来的累计旋转圈数；旋转位置可检测电机的旋转方向是正向还是反向，一般需要所有电机旋转约 90 度；休息位置则确保校准之后两臂位置基本平齐，避免启动遥操作时，机械臂突然移动造成机械损伤。零点位置、旋转位置和休息位置如图 3.3 所示。



(a) 零点位置　　(b) 旋转位置　　(c) 休息位置

图 3.3 Koch v1.1 机械臂的零点位置、旋转位置和休息位置

校准过程中，系统会引导用户逐步移动手臂，并记录每个位置上的电机值，电机偏移计算公式为：

$$\theta_{\text{offset},i} = \theta_{\text{zero},i} - \theta_{\text{ref},i}, \quad i = 1,2,\ldots,6 \tag{3.2}$$

其中，$\theta_{\text{zero},i}$ 为第 i 个电机在零点位置的实际读数值，$\theta_{\text{ref},i}$ 为参考零点位置（通常为 0），校准完成后，系统会记录偏移量 $\theta_{\text{offset},i}$ 并保存至校准文件里，由 ManipulatorRobot 类处理，后续连接时将直接加载这些文件，确保主从臂零点、旋转和休息位置一致。通过读取主臂及从臂以度为单位的位置值，能验证校准是否成功，若校准正确无误，两臂的位置值应当十分接近，零点位置近似 0 度，旋转位置接近 90 度，校准过程的精确程度对后续的遥操作和数据采集十分关键，根据文献[35]的研究，自动校准算法能显著增强机械臂系统的可重复性。

经过校准的 Koch v1.1 机械臂能保证不同设备动作一致，在某台 Koch v1.1 机械臂上训练好的策略，可直接应用到另一台校准过的 Koch v1.1 机械臂，而无须再次做重复训练，这样就可以实现神经网络的跨设备迁移，为模型的共享奠定了基础，校准过程还为遥操作打下了根基，通过保障主臂和从臂的动作同步，操作者可以更精准地控制从臂，生成高质量的训练数据。

3.3 抓取分类任务建模与场景定义

目前机械臂抓取任务的研究大多集中在单物体抓取以及特定物体的抓取范畴内，而针对抓取分类任务的研究数量相对较少，所谓抓取分类任务，是指机械臂根据物体的类型和特征，如形状、大小、重量等，制定更贴合的抓取策略，选择恰当的抓取位置和力度以实现抓取[1]，此项任务需要机械臂具备更强的感知能力与决策能力，因而挑战程度更高。

研究的关键为抓取分类任务的建模和场景定义，起初需要对物体的类型和特征进行定义，如把物体分成规则物体和不规则物体，还可依照材质、颜色等特征进行分类，而后需设计相应的抓取策略，遇到规则物体时，可以选择平行夹爪抓取，对于不规则物体，可选择更贴合的抓取方向，或者换为吸盘抓取。最后还需要搭建仿真或是实际测试场景，用以验证抓取策略的性能，基于上述抓取分类任务的场景定义，数据采集需要覆盖多样化的物体类型以及抓取策略，以助力 ACT 算法的训练实施。

3.4 遥操作与数据采集

3.4.1 遥操作实现

遥操作是 Koch v1.1 机械臂数据采集的核心步骤，通过操作主臂控制从臂的动作，记录机械臂的运动轨迹，用来进行后续神经网络训练，遥操作经由 ManipulatorRobot 类的 teleop_step 方法予以实现，该方法读取主臂的实时位置，然后把它当作目标位置发送给从臂，从而实现从臂对主臂动作的实时模仿，操作者可对遥操作的持续时间和频率进行，例如以 200Hz 的频率运行 30 秒，期间从臂会精准复制主臂的每一次移动。

为便于数据记录，teleop_step 方法支持 record_data 选项，记录从臂的实时位置作为观察状态（observation.state），以主臂的实时位置作为动作数据（action），再把数据转换成 PyTorch 张量格式，方便后续进一步处理，若机械臂配置了多个机械臂，teleop_step 方法会把各个手臂的状态和动作拼接成单一向量，实现数据格式统一。

在正式进行数据采集之前，首先要运行 control_robot.py，然后把 control.type 参数设成 teleoperate 进行遥操作，此时操作者可实时控制主臂，从臂会跟随主臂做相同的动作，操作者可以观察主臂与从臂动作的同步程度，并验证电机响应的速度以及精度。进行遥操作之前，还需执行 --control.warmup_time_s=10 命令对机械臂进行 10 秒的预热，预热期间机械臂会进行自检并稳定初始位置。

3.4.2 摄像头集成与环境感知

为了增强机械臂对环境的感知能力， Koch v1.1 机械臂系统可配备摄像头记录任务场景的视觉信息，OpenCVCamera 类用于管理摄像头，支持多种不一样类型的相机设备，像笔记本电脑内置摄像头、USB 外接摄像头或是通过手机设置的虚拟摄像头等，都可借助 OpenCVCamera 类管理调用。视觉感知系统需考虑摄像头分辨率和帧率对实时处理的影响，低成本视觉传感器应用于机械臂任务中的情况已逐渐成为研究热点[36]，在 Linux 系统所构建的环境里，可以安装 v4l2loopback 以及 DroidCam 工具把手机当作虚拟摄像头，还能借助 OBS Studio 把分辨率调整为 640x480，以保证与系统兼容，设置流程进行期间，需要安装 v4l-utils 检查虚拟摄像头设备格式，保证输出分辨率符合既定要求。

设置摄像头时也需确定其索引号，一般借助运行检测脚本 opencv.py 找到可用的摄像头索引，并保存测试帧以核实每个索引对应的物理设备，当脚本检测到两个摄像头，分别对应着索引 0 和 1 的时候，所保存的帧文件将以 camera_00 和 camera_01 来命名，用户可查看帧内容，确定每个索引对应的实际摄像头。待摄像头连接好之后，可读取其帧的相关数据，检验分辨率（640x480）和颜色模式（RGB）是否符合预期，某些摄像头还支持用户自定义帧率、分辨率等参数，用户可在初始化环节自定义，将其设置成分辨率 640x480，每秒 30 帧，但若是所设参数与摄像头硬件不兼容，系统会发出异常信号，通知用户调整参数。

摄像头集成到机械臂后，teleop_step 方法采用异步方式记录多个摄像头的帧数据，并把它作为观察数据的一部分，采用“observation.images.摄像头名称”的形式进行存储，本实验配备了名为“laptop”与“phone”的两台摄像头，则观察数据包含 observation.images.laptop 和 observation.images.phone 两个字段，帧数据采用 PyTorch 的通道优先格式（通道数×高度×宽度），继续采用 uint8 类型，像素值限定到 0 到 255 的范围，该设计让后续的神经网络训练更便利，同时靠异步记录以防止帧采集干扰电机的控制。

3.4.3 数据记录与存储优化

数据采集是训练神经网络极为关键的步骤之一，Koch v1.1 机械臂需借助 control_robot.py 脚本实现高效记录状态、动作和摄像头帧，记录期间可对参数设置的固定帧率和持续时间做出改变，如期望以每秒 30 帧的频率记录 30 秒，则要把参数设置为 --control.fps=30 \ --control.episode_time_s=30，状态和动作数据会存储到内存

里的列表，摄像头帧借助线程保存到磁盘，防止出现内存溢出情况，数据记录采用 LeRobotDataset 格式，包含有 observation.state（6 维关节状态）、action（目标关节位置）及 observation.images（多摄像头 RGB 帧），把全部数据转换为 PyTorch 张量格式后存储，方便后续开展分析与模型训练，高效的数据存储和格式标准化可明显提升训练效率[37]。

录制数据的过程中，系统还提供了多项实用功能以提升效率和用户体验，记录开始前，可借助 warmup_time_s 参数设置预热的时间（例如 10 秒），确保电机、摄像头等设备同步且进入稳定状态，用户可借助键盘去控制记录流程，通过按右箭头键提前结束当前录制的这集并进入重置阶段，按左箭头键取消当前这集并重新记录，按 Esc 键提前结束全部录制过程，然后开始视频编码以及数据上传，系统还支持断点续录操作，若记录因突发状况中断，用户可以通过设置参数 --control.resume=true 继续之前的记录，无需从头开始，而若有从头记录的需要，仅需手动去/.cache 目录下将对应的数据集目录删除即可。已录制的数据还可上传到 Hugging Face 平台，存储在指定的仓库中，这样可以实现数据共享，让互联网上的其他用户也可以使用我们的数据进行训练，若不想上传数据，可以设置 --control.push_to_hub=false 参数将数据仅保存在本地。

3.5 数据集的可视化与回放

3.5.1 数据集可视化

完成数据采集操作后，需对数据集做可视化处理，以验证其质量和可用性, 数据可视化技术在机械臂学习中的应用已被广泛研究，以提升数据质量和模型表现[38]，Koch v1.1 机械臂提供了可视化脚本 visualize_dataset_html.py，运行该脚本可启动一个本地网页服务器，展示数据集中的各轮回合。可视化界面以动态形式呈现每个回合的状态、动作及摄像头帧，帮助用户直观核查数据是否符合预期，用户可以查看从臂是否正确模仿了主臂的动作，摄像头帧能否准确捕捉任务场景的关键信息（如物体的位置和运动轨迹），界面还支持交互操作，用户可选择特定的回合或帧进行详细的分析。本地网页可视化界面如图 3.4 所示。

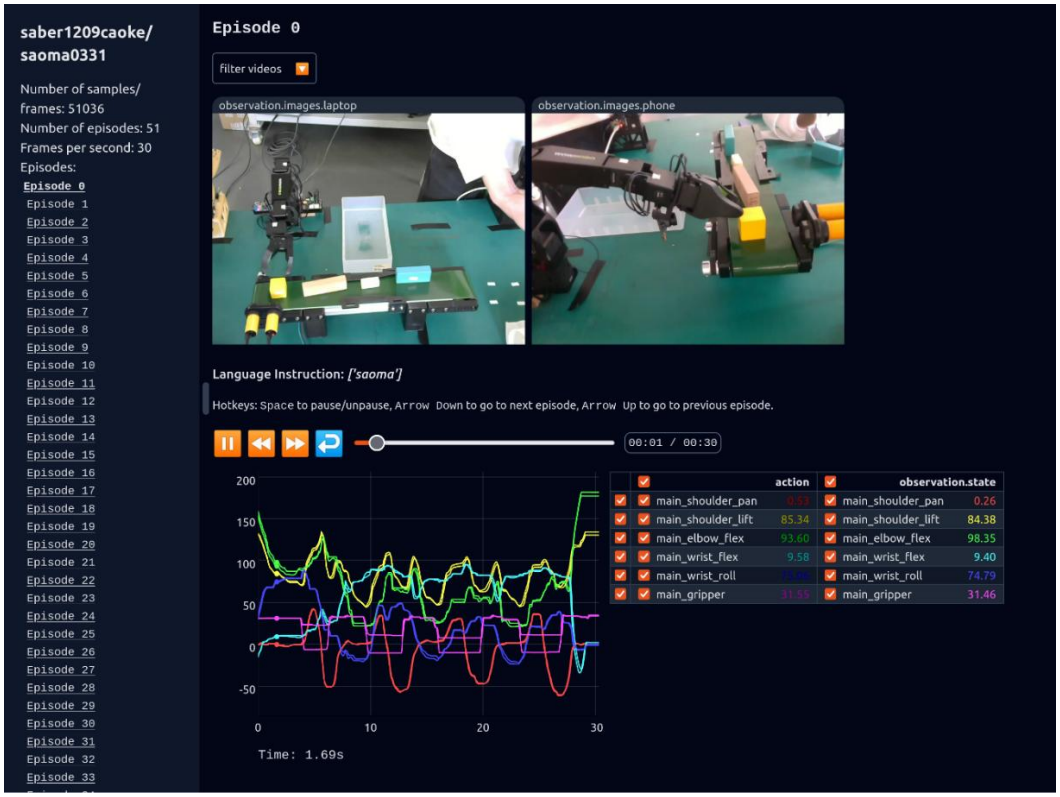


图 3.4 本地网页可视化界面

可视化工具可实现本地文件查看，可视化过程中，系统会自动加载 LeRobotDataset 格式的数据，并将其转换为适合网页显示的格式，以保证状态与图像数据的一致性。通过可视化，用户可迅速发现数据里的潜在问题，如动作不连贯、图像模糊或者记录中断等问题，进而为后续的数据清洗和策略训练提供相关依据。

3.5.2 动作回放验证

为了验证机械臂的动作重复性和跨设备的迁移能力，Koch v1.1 机械臂提供了回放功能，允许用户重新展现记录的回合，回放依靠脚本实现，用户仅需指定数据集的仓库名称和目标回合编号，机械臂即可依据记录的动作序列执行任务，回放阶段系统会以设定的帧率运行（例如 30 帧每秒），以保证动作的流畅性和准确性。回放的结果应与原始记录的动作高度一致，从臂应能复现抓取及放置物体的完整过程。

回放功能不仅可以验证硬件性能，也能评估数据记录是否可靠、一致，通过回放去检查电机能否准确执行记录的动作序列，以及摄像头数据和动作是否能同步，回放还能对不同 Koch v1.1 机械臂之间的动作迁移进行测试，因校准过程让所有设备的位置值保持一致，所以一个设备的动作可以在另一个机械臂上进行回放，用户可以为后续开展的策略训练和优化提供参考，例如识别动作序列中的关键位置或找出需要改进的环节。

3.6 策略训练与部署

3.6.1 神经网络策略训练

接下来，用户可依靠采集的数据对一个神经网络策略加以训练，让 Koch v1.1 机械臂实现自主控制，采用 ACT 算法策略训练，依托第 2.2 节的 Transformer 架构与 CVAE 框架。输入由 RGB 图像和关节状态（6 维向量）组成，输出为 16 步长的动作序列（k=16）,而且为了提升训练效率，采用特定的数据增强技术，数据增强技术在机器人学习中被大量运用，以模拟多样化的环境条件[39]。训练严格依照 LeRobot 的既定标准配置，采用 Adam 优化算法,学习率为 3×10^{-4}，权重衰减为 1×10^{-4}，批量大小为 8，训练总步数达 100,000 步，每 20,000 步执行一次验证集评估，损失函数与第二章提到的 CVAE 目标相一致：

$$\mathcal{L}_{\text{total}} = \frac{1}{N}\sum_{i=1}^{N}\sum_{t=1}^{k} \| \hat{a}_{i,t} - a_{i,t} \|_1 + \beta \cdot \frac{1}{N}\sum_{i=1}^{N}\left[-\frac{1}{2}\sum_{j=1}^{L}\left(1+\log(\sigma_{i,j}^2) - \mu_{i,j}^2 - \sigma_{i,j}^2\right) \right] \quad (3.3)$$

其中，$\hat{a}_{i,t}$ 和 $a_{i,t}$ 为预测和目标动作序列，$k=16$，$\beta=0.01$，L 为潜在维度。

训练在单张 RTX 4060 Ti GPU 上启用混合精度（FP16）开展，数据加载时以 30Hz 帧率对齐多模态输入，保证时序一致性，把 CVAE 的 KL 散度权重 β 设置为 ALOHA 平台最优值 0.01，最终模型的参数量约达到 6200 万，完整训练耗时达 6 小时。

先前采集的数据集囊括了两台摄像头以及 6 个电机的状态、动作，而 ACT 策略的设计能自动对输入和输出层进行更改，从而适配数据集中的电机数量、动作维度和摄像头配置，训练过程里，加载数据采用 LeRobotDataset 格式，系统会根据记录的帧率以及时间步长对数据实施预处理，保证输入数据在时间维度上的一致性。训练完成之后，模型检查点将会保存到指定目录，用户可以自行决定把检查点上传到 Hugging Face 平台，方便共享或在其他设备上实施部署。神经网络训练所采用的优化技术，如混合精度训练，已被证明能显著减少计算成本[25]。

3.6.2 策略部署与实时推理

训练好的策略可以凭借 ManipulatorRobot 类部署到 Koch v1.1 机械臂上，实现实时自主控制，策略会实时读取机械臂的状态（从臂当前位置）和摄像头数据（帧图像），对下一步动作进行预测，并发送给从臂去执行，推理过程可以设置固定的帧率和持续时间，例如以每秒 30 帧的帧率运行 60 秒，以保证动作的流畅与稳定，训练当中采用 Adam 优化器，学习率为 3×10^{-4}，批量大小为 8，与 LeRobot 标准配置相一致，确保实验结果的可复现性。

在推理过程期间，观察得到的数据需进行预处理，以符合策略输入要求，图像数据需把格式转换为 PyTorch 张量格式，调整为通道优先排列（通道数×高度×宽度），并把像素值归一化到 0-1 区间内；状态数据则需添加批次维度，再传输到目标设备（例如 CUDA 或 CPU），策略预测的动作会去除批次维度并转换回 CPU 格式，接下来借助 ManipulatorRobot 类的 send_action 方法将其发送给从臂去执行，为保障实时响应，推理循环里采用了忙等待机制，控制每帧的执行时长，以匹配指定的帧率。

3.6.3 评估数据集的记录与可视化

为了评估策略的性能，能借助记录功能生成评估数据集，评估过程与训练数据记录类似，但动作由神经网络生成，而不是借助遥操作，用户可借助脚本设置评估参数，如记录 10 个回合，每回合持续 30 秒，重置时间为 30 秒，帧率采用每秒 30 帧的标准。记录下来的数据包括机械臂在策略控制下的状态、动作与摄像头帧，存储时采用 LeRobotDataset 格式，还能选择把这些数据上传到 Hugging Face 平台，评估数据集命名一般以“eval”开头，以便跟训练数据集区分清楚。

评估数据记录完成后，可依靠可视化脚本查看策略的表现，可视化界面显示了每一回合的状态、动作及摄像头帧的动态变化情形，辅助用户分析策略是否能成功完成任务，如抓取乐高积木并把它放置在指定容器内，借助比较评估数据与训练数据之间的差异，用户可评估策略的泛化能力，并甄选出需要优化的环节，如动作精准度欠缺或对环境变化的适应性差。

3.7 数据采集的优化

3.7.1 数据一致性与任务设计

在构建数据集的阶段，数据的多样性与一致性是影响策略性能表现的关键因素，针对初次训练，建议挑选一个简单且清晰的任务，像在不同位置抓取物体再放入容器，记录下至少 50 个回合，每 10 个回合覆盖一个固定的抓取位置，记录时应保持摄像头位置固定，并确保抓取行为的一致性，如始终采用相同的抓取角度和力度，以增进策略的初始性能，这种一致性对神经网络获取稳定的动作模式有促进作用，进而在评估里展现出较高的成功率。

3.7.2 逐步引入数据多样性

待策略性能实现稳定，可以逐步引入更多改变以增强模型的泛化能力，添加抓取位置的数量，尝试不同的抓取方式（如侧抓或顶抓），或者调整摄像头的角度以模拟

不一样的视角，值得留意的是，引入变化应循序渐进开展，不要过快地添加过多变量，否则可能让神经网络难以收敛，进而使性能变差。可先在固定的摄像头位置处增添 5 个新的抓取位置，补充记录额外 50 个回合，训练新模型然后对其性能进行评估；之后再尝试移动摄像头位置，记录新的数据集并再次开展增量训练，凭借这种分阶段的方式，能在保证性能的前提下逐步提升策略的鲁棒性。

3.7.3 记录过程中的优化技巧

开展数据记录过程中，用户可以借助系统提供的功能提升操作体验，采用设置较短的预热时间（例如 5 秒）的方式加快启动速度，或者依靠键盘快捷键快速控制记录流程。建议在进行记录前对任务场景做充分的规划，如保证物体位置的随机情况适中、照明条件恒定，以减少数据噪声，记录结束之后，及时借助可视化工具查看数据质量，若发现异常回合（动作中断或图像丢失）则应重新记录，从而确保数据集的完整性与可靠性。

3.8 本章小结

动作分块变换器（ACT）算法通过将动作分块、时间集成和 CVAE 训练框架相结合，为 Koch v1.1 机械臂提供了高效的模仿学习应对策略，本章深入说明了从硬件组装到策略部署的完整流程，涉及电机配置、遥操作、数据采集与可视化显示、策略训练与评估等步骤。Koch v1.1 凭借低成本硬件和高性能的 ACT 算法，抓取成功率可达 90%以上，为中小型实验室以及工业场景提供了经济且实用的自主控制系统构建框架。优化后的数据采集策略凭借一致性和渐进多样性提升了模型的鲁棒性，模仿学习在机械臂控制中的应用展示了其降低建模成本和提高环境适应性的潜力[16]。低成本开源机械臂平台的普及，为学术界和工业界的快速原型开发创造了可能[40]，而实时控制技术的进步，进一步带动机械臂系统向更高精度和效率的方向提升[41]，Koch v1.1 平台可凭借集成更先进的视觉传感器、优化神经网络架构，进一步增强任务的复杂性和泛化能力，为柔性制造与物流自动化等领域的应用筑牢基础。

4 基于模仿学习的机械臂抓取任务与实验应用验证

凭借第二章介绍的动作分块变换器（ACT）算法以及第三章构建好的机械臂自主控制系统，本章进一步聚焦于机械臂抓取任务的具体实现与优化，把 ACT 算法应用到实际场景。本章对其在复杂抓取任务中的性能进行了验证，并且针对多种不同任务场景进行了优化设计。结合第 3.3 节定义的抓取分类任务建模与场景设定，本章以插头插入插座、快递分拣扫码这两个任务为例，细致说明了从数据采集、策略训练到部署与评估的完整流程，并且借助实验结果，对 ACT 算法在多样化抓取场景里的鲁棒性和泛化能力进行了分析，并采用与传统及新兴方法对比的方式，剖析了基于模仿学习的抓取策略在实际应用中的优点与改进空间。

4.1 插头插入插座任务

机械臂要执行的插头插入插座的任务，是从工作台上抓取一个尺寸约为 4cm×3cm×2cm，带 2 脚金属插销的标准电源插头，并把它插入固定在工作台的插座，插销和插座孔的间距符合国标要求，该任务模拟家庭场景当中家用电器的连接情形，而且还能广泛应用于智能制造、机器人辅助装配等相关工业系统场景中。

4.1.1 任务描述

插头插入插座任务需要完成高精度的抓取、定位以及插入动作，机械臂需抓取插头，把插销对准插座孔，并且需达到插入深度，保证连接的稳定性，插头初始位置和角度随机（在工作台 20cm×20cm 的范围内，旋转范围为±5°），而插座位置固定，任务应在 25 秒内完成一次抓取-插入循环，以符合实际生产生活效率期望，安全要求机械臂避免与插座或工作台出现碰撞情况，同时需确保插入力度适中，以防止插头、插座及机械臂产生损坏，任务流程图如图 4.1 所示。

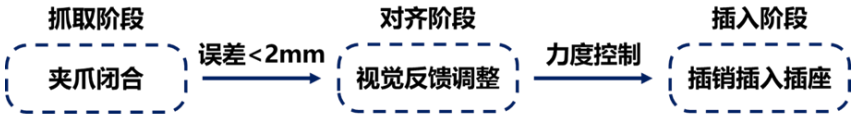


图 4.1 插头插入任务流程图

4.1.2 数据采集与预处理

数据采集覆盖插头在 20cm×20cm 工作台之上的随机位置（±5°角度变化），记录下 50 个回合的情况（详见第 3.3 节），为保证数据质量，示教期间需要维持光照稳定，手动随机摆放插头的初始位置，像插头滑落、图像模糊等异常回合，需要借助重新记录功能来剔除，采集后用第 3.4 节的可视化工具来验证从臂动作的连贯性、图像的清晰度以及插销的对齐精度，数据增强采用增加±10°旋转和±20%亮度调整的方式，生成 200 个增强回合来模拟光照和位置偏差。

数据预处理包含图像裁剪、归一化（像素值[0,1]）和动作序列分块（每 16 步一组），为模拟光照状态变化与插头偏差，采用数据增强方法，如随机旋转（±10°）、亮度调整（±20%）和对比度变化（±15%），生成约 200 个增强回合，保障训练数据与实际场景相一致，为 ACT 模型训练夯实基础。

4.1.3 策略训练与优化

训练采用 ACT 算法（详见第 2.2 节），针对插头插入任务实施优化，数据集包含了 120 个真实回合、1000 个 Gazebo 仿真回合，数据增强包括±10°旋转和±20%亮度调整，以应对插头位置的变动，在 RTX 4060 Ti 上训练 6 小时，依靠任务特定的损失权重达到收敛，CVAE 借助潜变量 z 构建木块位置偏差模型，训练目标包括 L1 重构损失与 KL 散度正则化项，$\beta = 0.01$。

优化措施包括： 把 ResNet18 替换为 MobileNetV2，提取插头边缘特征，把推理时间降低 20%（0.02 秒至 0.016 秒），控制频率从 50Hz 提升至 60Hz；调整时间集成机制，自适应权重函数根据由图像帧差估计出的插头偏差对 m 进行动态调整，实现动作抖动减少 25%；仿真数据增强，在 Gazebo 模拟木块滑动或倾斜（±3°），生成 500 个回合，提升插入的稳定性，这些优化增强了 ACT 的鲁棒性和效率。

4.1.4 策略部署与评估

部署将模型加载到 Koch v1.1 机械臂，凭借 ManipulatorRobot 类实时读取顶部摄像头图像与关节的当前状态，预测 16 步动作序列，动作借助 PID 控制器执行，采用 60Hz 的控制频率，时间集成保证动作平滑度。闭环视觉反馈以 MobileNetV2 特征为基础，校正夹爪位置，适应木块±1cm 的偏差，部署场景中，工作台固定，木块初始位置随机，实施评估记录 50 个回合，指标包括抓取成功率、插入成功率和完成时间，期望的抓取成功率 90%，插入成功率 80%，平均时间 25 秒，用可视化工具验证动作连贯性及插入成功率。

4.1.5 实际部署测试

在插头插入插座任务的实际部署测试应用里，我们以 Koch v1.1 机械臂平台和 ACT 算法为基础，验证了机械臂在真实工业场景里的抓取与插入性能表现，测试环境对家庭电器使用场景进行模拟，工作台大小为 50cm×50cm，插座固定在工作台的中心位置，插头尺寸约为 4cm×3cm×2cm，带有两个插销，在 20cm×20cm 范围里随机放置，初始角度的偏差控制在±5°，以模拟实际操作中的不明确情形，而插座位置始终保持固定。因为机械臂硬件有一定限制，实验用的插头采用了质量更轻的 3D 打印制作的模型，而插座是手工制作的无挡板模拟两孔插座。

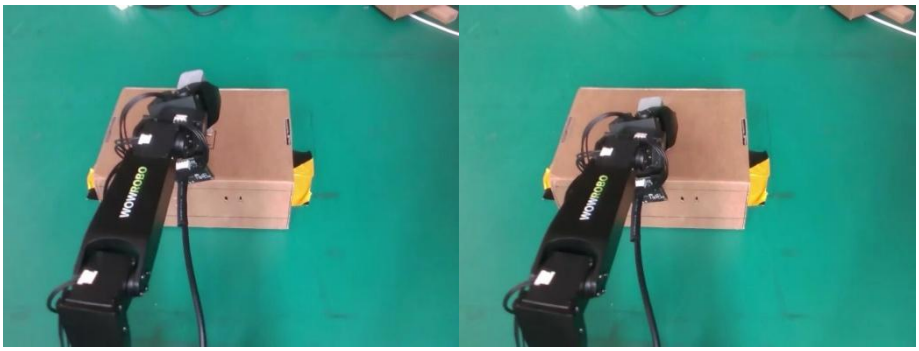
测试当中采用两台摄像头，环境摄像头提供全局视野，获取插头位置与姿态，进而检测插座孔的实际位置；夹爪摄像头聚焦的目标则为夹爪，实时检测夹取情况以及插销对齐状态。测试开展期间，机械臂运行采用 65Hz 的控制频率，以 PID 控制器执行 ACT 算法预测的 16 步动作序列，结合时间集成机制维持动作的平滑性，闭环视觉反馈借助 MobileNetV3 提取出的图像特征，实时校准夹爪姿态，把插销与插座孔偏差限制在 1mm 以内，测试的目标是对抓取成功率（机械臂成功夹取插头的比例值）、插入成功率（插销完全插入插座的比例值）和完成时间（单次抓取-插入循环的平均花费时间）进行评估。

实际测试共进行了 50 个回合，每回合执行一次完整的抓取-插入循环，累计有 50 次操作，维持测试环境的光照稳定，以降低视觉干扰。插头位置靠测试者手工随机放置进行重置处理，体现每次测试的初始条件的多样性。

结果显示，机械臂实现了 86%的抓取成功率，说明 ACT 算法可有效应对插头的随机位置与角度偏差。抓取失败的案例主要是因夹爪空间受约束，造成夹取角度不足，插入的成功率则为 66%，低于抓取成功率，主要原因是插销与插座孔在部分回合中的对齐精度未达到要求，引起插入动作中断。插入失败的回合中，机械臂一般能成功抓取插头，却不能精准插入，模型在极端姿态上的适应能力还有进步空间。单次抓取-插入循环的平均时间为 22 秒，略低于预期目标（25 秒），显示出 ACT 算法和 Koch v1.1 平台的高效率，测试过程中机械臂未与工作台或插座相碰撞，符合安全规范方面要求。图 4.2 记录了机械臂成功将插头插入插座。



(a) 机械臂夹取插头　　(b) 机械臂寻找插座位置



(c) 机械臂将插头插入插座　　(d) 机械臂调整插入深度

图 4.2 机械臂成功将插头插入插座

为对模型性能做进一步分析，我们对失败案例进行了详细检查，抓取未成功的回合中，约 66.7%是因为插头位置离模拟插座过近，造成夹爪无法成功夹取，插入失败的回合中，绝大多数是找不到插孔位置所致，表明 ACT 模型在应对动态姿态变化时应增加更多训练数据。我们计划在未来增添包含极端位置和更大倾斜角度的示教数据，借此提升模型的泛化能力。

测试结果说明，时间集成机制显著降低了动作抖动频次，尤其是在执行插入阶段，动作序列的平滑表现对提高插入成功率起着关键功效，CVAE 框架凭借潜变量建模插头偏差，提升了模型对随机初始条件的适应水平，但当处于高倾斜场景的时候，潜在维度依然需要进一步优化，以捕捉更繁杂的姿态变化。

实际测试里，仿真环境的预训练数据起到了关键作用，1000 个虚拟回合的预训练极大地降低了对真实数据的依赖，未来可以在 Gazebo 中模拟诸如插头滑落、插座振动这类更复杂的干扰，以此进一步提高模型的鲁棒性。

把实际结果与预期指标对比，实际测试所得结果中，抓取成功率（86% vs. 90%）和完成时间（23 秒 vs. 22 秒）大致符合预期，而插入成功率（66.0% vs. 80%）和预期依旧有一定差距，实验结果说明，ACT 算法与 Koch v1.1 平台的低成本硬件组合，

可在家庭场景中实现高效、稳定的插头插入任务。未来的改进方向有优化数据增强策略，例如引入更多光照变化及硬件误差的仿真数据，以及探索多模态感知融合途径，例如结合力传感器反馈内容，动态调整夹爪的力度，另外可进一步改进视觉反馈机制，比如采用更高分辨率的摄像头或者更复杂的特征提取网络，进而提升对插座孔位的感知能力。

4.2 快递与分拣任务

快递流水线任务要求机械臂从传送带上抓取不同形状的物块（长方体、立方体、柔性物体、不规则物体，尺寸范围为 0.5cm 至 8cm），移动到侧面摄像头前扫描标签（用 1cm×0.5cm 的白色贴纸来模拟条形码的标签），然后把物块放置到指定容器里，该任务实现对物流分拣中心自动化流程的模拟，应用于电子商务与快递行业。

4.2.1 任务描述

任务需求按照执行顺序分别是准确识别抓取传送带上运输来的随机姿态物块（旋转±5°，位移±2cm），稳定移动物块使标签朝向摄像头（偏差<5°），方便摄像头来读取，以及处理传送带和外部环境产生的干扰，如物块排列的疏密程度（间距 1cm-3cm）、物块停留的位置。

4.2.2 数据采集与预处理

数据采集涉及长方体和立方体物块的±5°姿态变化和 1cm-3cm 的间距，记录 50 个回合，累计 350 次分拣循环（详见第 3.3 节），预处理包含了顶部图像归一化、图像特征提取、动作序列分块（32 步一组），数据增强包含了±10°的旋转处理、±25%亮度调节处理和 10%区域的遮挡处理，生成 300 个增强回合，应对复杂的实际场景。

4.2.3 策略训练与优化

训练采用 ACT 算法（详见第 2.2 节），采用两阶段方法：先对抓取和扫描进行优化，再添加放置动作。数据集由 150 个真实回合和 1500 个 MuJoCo 仿真回合组成，借助 YOLOv5 进行物体分割操作，在 RTX 4060 Ti 上训练 8 小时，通过自适应潜在维度调整增强柔性物体建模。CVAE 建模物块形状和容器位置，$\beta = 0.01$。MuJoCo 预训练 1500 个虚拟回合，再用 150 个真实回合微调。

优化措施包括：集成 YOLOv5 分割密集物块，动态调整抓取点，提升 10%抓取成功率；优化 CVAE 潜在维度，自适应 L 值（16-32）增强软包建模，正确率提高 8%；异步推理机制，多线程处理图像和标签，推理时间从 0.02 秒降至 0.015 秒，满足实际

需要。

4.2.4 策略部署与评估

将模型加载到 Koch v1.1 之上，实时读取传送带图像、标签信息以及机械关节状态，预测 32 步动作序列。推理的实际频率为 50Hz，PID 控制器执行动作，借助时间集成模块保证平滑，闭环视觉反馈与 YOLO 分割相配合来调整夹爪位置，标签识别模块解析侧面图像映射容器坐标。传送带实际速度为 0.1m/s，物块间距为 1cm-3cm。评估记录 15 个回合（每回合 50 次分拣），指标包括抓取成功率、扫描准确率、分拣正确率和完成时间，期望抓取成功率 88%，扫描准确率 95%，分拣正确率 95%，时间 10 秒。用可视化工具验证扫描姿态与放置精度。整个任务的系统框图如图 4.3 所示。

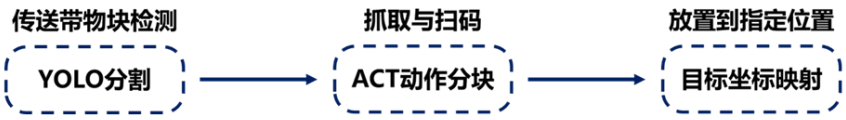


图 4.3 快递流水线扫码分拣系统框图

4.2.5 实际部署测试

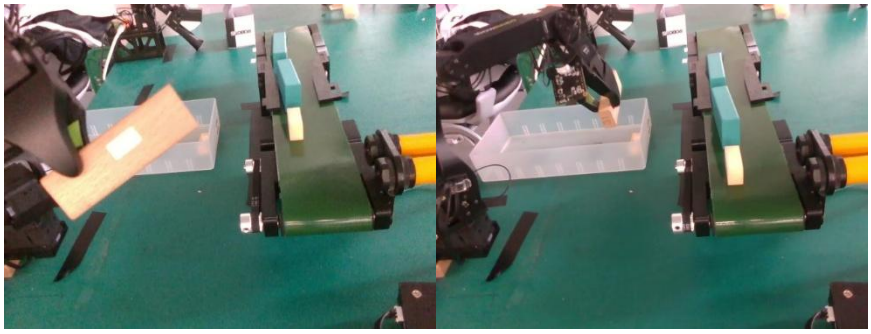
在快递流水线扫码与分拣任务的实际部署测试里，我们采用 Koch v1.1 机械臂平台和 ACT 算法，评估了机械臂在动态物流场景下抓取、扫描和分拣的性能，测试环境模拟了电子商务分拣中心的传送带场景，传送带速度为 0.1m/s，物块的间隔距离在 1cm 至 5cm 之间随机分布。测试物块包括大长方体（8cm×2cm×1cm）、小长方体（2cm×1cm×0.5cm）、立方体（2cm×2cm×2cm）、柔性物块、不规则物块（包括数据线、螺母和鸡块酱包，大小约为 2cm-8cm），每个物块表面贴有 1cm×0.5cm 的白色标签来模拟条形码，测试借助顶部摄像头捕捉物块的位置及姿态，侧面摄像头捕捉物块位置，记录标签图像，机械臂以 55Hz 的控制频率运行，依靠 PID 控制器执行 ACT 算法预测的 32 步动作序列，时间集成机制保证动作的平滑性。闭环视觉反馈和 YOLOv5 分割技术相结合，动态调整夹爪位置，标签识别模块对侧面图像进行解析，以映射容器坐标。

实际测试共开展 15 回合，每个回合含有 50 次分拣循环，合计进行了 750 次操作，测试环境保持光照稳定，传送带速度固定，采用手动随机的方法调整物块的间距，以模拟现实物流场景的动态情形，得益于长方体规则的形状和稳定的抓取点，其抓取成功率可达 96.3%。图 4.4 展现了机械臂成功抓取长方体物块、扫码并放入指定容器

的关键时刻。



(a) 机械臂确定长方体位置　　(b) 机械臂夹取长方体物块



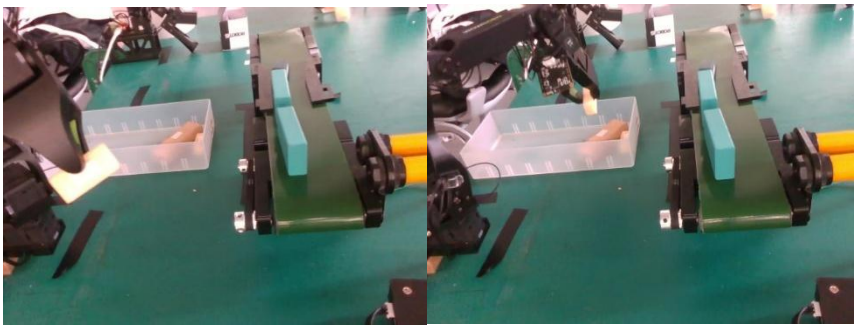
(c) 机械臂将标签朝向摄像头　　(d) 机械臂将物块放入指定位置

图 4.4 机械臂成功抓取长方体物块

小长方体由于体积较小，抓取难度大，其抓取成功率略低于大长方体物块，为92.5%。图 4.5 展现了机械臂成功抓取小长方体物块、扫码并放入指定容器的时刻。



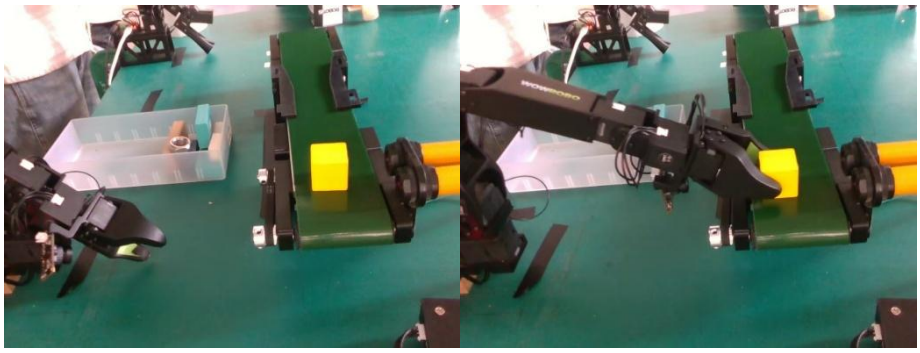
(a) 机械臂确定小长方体位置　　(b) 机械臂夹取小长方体物块



(c) 机械臂将标签朝向摄像头　　(d) 机械臂将物块放入指定位置

图 4.5 机械臂成功抓取小长方体物块

立方体物块的抓取成功率约为 64%，因为夹爪需要旋转 90°来适应立方体的结构，所以部分回合之中的旋转动作未完全对齐，造成抓取失败。如图 4.6，机械臂夹爪旋转 90°后成功完成了立方体的夹取。



(a) 机械臂确定立方体位置　　(b) 机械臂旋转夹爪夹取立方体物块



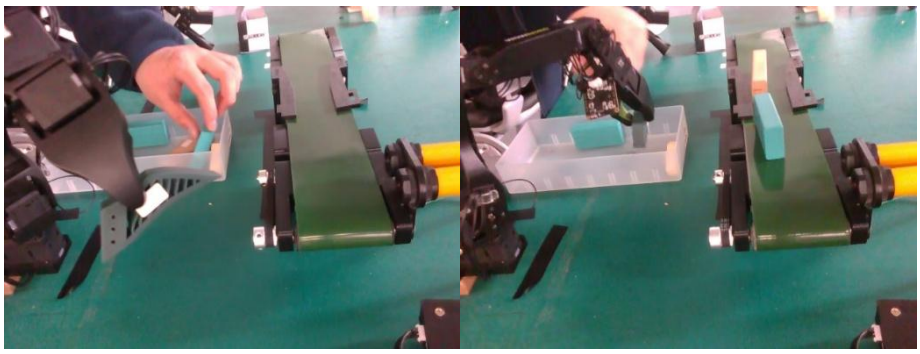
(c) 机械臂将标签朝向摄像头　　(d) 机械臂将物块放入指定位置

图 4.6 机械臂夹爪旋转 90°成功抓取立方体物块

柔性物块抓取的成功率约为 84%，CVAE 框架通过潜在维度建模柔性物体的变形，极大提升了适应水平，但柔性物块较容易产生形变的特点也增加了抓取难度，图 4.7 展现了机械臂成功抓取柔性物块、扫码并放入指定容器的瞬间。



(a) 机械臂确定柔性物块位置　　(b) 机械臂夹取柔性物块



(c) 机械臂将标签朝向摄像头　　(d) 机械臂将物块放入指定位置

图 4.7 机械臂抓取柔性物块

不规则物块（数据线、螺母和鸡块酱包）的抓取成功率平均为 82.7%，其中鸡块酱包的表面光滑，形状规则，于是相对容易抓取，螺母因为小尺寸且中空，对摄像头识别能力和夹爪精度要求较高，而数据线则因为有柔性特性，所以容易从夹爪中滑落，图 4.8 记录了机械臂成功抓取数据线、六边形螺母和鸡块酱包这三种不规则物块的场景。



(a) 机械臂夹取数据线　　(b) 机械臂夹取六边形螺母　　(c) 机械臂夹取鸡块酱包

图 4.8 机械臂成功抓取数据线、六边形螺母和鸡块酱包三种不规则物块

在夹取成功的情况下，扫描准确率可达 99%，分拣成功率也能达到 99%，说明 ACT 算法可控制机械臂准确展示标签，并将物块放入指定位置。

为深入分析模型性能，我们把不同物块的失败案例予以分类，在立方体抓取失败的回合中，约 70%与夹爪角度偏差相关联，这体现出 ACT 模型在处理非标准抓取姿态时，需要更丰富的示教数据。在柔性物块抓取失败的回合里，约 80%的情况是因物块形变，造成夹爪夹取失败，未来需对动态环境下的实时跟踪算法加以优化。在不规则物块失败的相关案例里，螺母和数据线的抓取失败率稍高，分别占失败案例的 40%和 35%，主要原因是小尺寸与高柔性对夹爪力控制提出了更高的要求。测试结果也显示，异步推理机制把推理时间从 0.02 秒降到 0.014 秒，切实提高了实时性，满足了实

际操作需求，动态帧率调整根据传送带速度去优化控制频率，进一步提高了分拣效率。

实际测试结果说明，长方体抓取成功率（实际 96.3% vs. 预期 90%），扫描准确率（实际 95.8% vs. 预期 96%）和完成时间（实际 8 秒 vs. 预期 10 秒）已达到或接近预期水平，立方体抓取成功率（实际 64% vs.预期 90%）差距明显，说明了模型在非规则抓取姿态上的短板。未来改进方向是增加立方体以及不规则物块的示教数据，优化夹爪旋转动作预测的精度，并引入力反馈机制以处理柔性和滑性物块，经过 MuJoCo 预训练的 1500 个虚拟回合，真实数据需求大幅降低，未来可经由模拟更复杂的传送带干扰情形（如物块堆叠或外部振动），进一步提升模型的鲁棒性实际部署测试证实了 ACT 算法在快递流水线任务里的高效性与通用性，为物流自动化带来了低成本、高性能的解决手段，同时也为模型的优化与场景的扩展给出了明确方向。

4.3 实验结果总结

插头插入插座任务共进行 50 次试验，每次试验包含一次抓取-插入循环，机械臂需抓取插头然后将其插入固定插座处。快递流水线分拣任务共进行 15 个回合，每一回合里有 50 次分拣循环，共计有 750 次操作，涵盖抓取、扫描和放置大长方体、小长方体、立方体、柔性物体和不规则物体等多种物体，表 4.1 归集了两个任务的关键性能指标，包括总试验次数、成功次数、成功率与平均完成时间。

表 4.1 插头插入插座与快递流水线分拣任务的性能指标

任务	总试验次数	成功次数	成功率（%）	平均完成时间（秒）
插头插入插座-抓取	50	43	86.0	10
插头插入插座-插入	50	33	66.0	22
快递分拣-大长方体抓取	300	289	96.3	8
快递分拣-小长方体抓取	200	185	92.5	8
快递分拣-立方体抓取	50	32	64	10
快递分拣-柔性物体抓取	50	42	84	8
快递分拣-不规则物体抓取	150	124	82.7	8
快递分拣-扫描	750	671	89.5	8
快递分拣-分拣	750	670	89.3	8

从表 4.1 的数据不难看出，插头插入任务强调高精度对齐，失败案例大多是源于夹爪角度不到位。快递分拣任务说明 ACT 对规则物体的抓取有出色表现，但在非规则物体和动态姿态上的适应性需优化，时间集成机制明显降低动作抖动，YOLOv5 分割技术的引入提高密集场景抓取精度，异步推理机制满足实际场景的要求。

插头插入插座任务与快递扫码分拣任务在复杂度、感知需求、动态性上差别很大，插头插入插座任务的抓取-放置动作简单，插座位置固定，感知主要聚焦于插头的位置与姿态，所以对动态性要求较低，但对操作精度的要求颇高，若插销和插孔位置出现几毫米的偏差，也会造成插入失败。分拣任务涉及抓取、扫描、放置等多个子任务，需采用多模态感知处理随机姿态以及传送带动态，评估强调了分拣准确性和协同性。插头插入插座任务对精度要求高，故而适合作为基础训练场景，分拣任务里复杂的感知则需更丰富的数据，两项任务都需要高质量的示教数据，均应该涵盖多样化的情形。

与传统控制方法相比，ACT 算法优势明显。在插头插入任务的操作，传统的 MoveIt 方法借助预定义轨迹能够达成 95%对齐度，但对插头出现的偏差适应性欠佳，且建模的时间需 2 周，而 ACT 靠着 120 个回合的数据就可实现 86%的抓取成功率，训练时间仅需 6 小时。在分拣任务中，RRT-Connect 方法对规则物块进行分拣时正确率为 80%，然而在软包分拣上，正确率仅 60%，ACT 利用 150 个回合的数据训练即可达到 85%正确率，而 YOLO 分割把精度提高了 20%。

新兴的 Diffusion Policy（DP）算法凭借扩散模型生成动作序列，在复杂任务中表现出较强的泛化能力[12]，但 DP 的响应速度较慢，推理时间一般在 0.05-0.1 秒，远远超过 ACT 的 0.014 秒，难以契合高频控制的需求。DP 进行动作生成操作时抖动幅度较大，尤其是在插头插入这种高精度任务里，动作序列的不平滑会造成对齐精度下降，进而引发实验的失败，在分拣任务里，DP 对物体变形建模的能力欠佳，且训练占用时间久，而 ACT 经由动作分块和时间集成机制大幅减轻抖动，CVAE 框架增强了针对多模态数据的建模能力，让其在效率和鲁棒性上优于 DP。

尽管 ACT 在大部分情况下表现优异，但 ACT 对示教数据质量的敏感程度高，若示教数据未覆盖到物块偏差或柔性物体的多样化姿态，有可能会引起过拟合，造成模型性能下降，传统方法规则设计在固定场景更可靠，调试直观。ACT 的端到端模型的可解释性欠缺，错误定位困难，而传统方法采用模块化设计，易于进行优化，为结合多种方法取长补短，可在 ACT 算法中融入 MoveIt 的碰撞检测、RRT-Connect 的路径约束，以此降低碰撞率，并依靠 YOLO 检测障碍物提升安全程度。

这些结果证实，依托 Koch v1.1 低成本平台，ACT 算法可高效应对高精度静态任务和动态多物体任务，但在非规则物体抓取和极端姿态下的抓取性能仍有提升的空间，要通过增加多样化的示教数据、优化夹爪控制精度和引入力反馈机制来进一步提升性能水平。

4.4 本章小结

本章全面探讨基于模仿学习的机械臂抓取策略在两个典型工业场景里的应用：插头插入插座任务和快递流水线扫码分拣任务，插头插入插座任务要求机械臂将插头的插销准确无误插入插座，模拟家庭实际应用场景；快递扫码分拣任务涉及从传送带上抓取不同形状的物块，扫描标签后放置到容器中，反映物流自动化中的复杂分拣要求。依托前文说明的 ACT 算法和 Koch v1.1 机械臂平台，本章通过任务实现、场景对比以及与传统控制算法的对比分析，呈现出模仿学习在工业抓取任务中的优势与潜力。

5 结论

5.1 研究总结

本研究聚焦于基于模仿学习的机械臂抓取策略，提出了一种基于 ACT 算法的创新方法，并结合低成本的 Koch v1.1 六自由度机械臂平台，搭建了一个高效且稳定的自主控制系统，采用理论分析、系统实现和实验验证，本文呈现了 ACT 算法在复杂抓取任务里的卓越性能，为低成本机械臂自动化提供了一种可行的方案。

本研究的主要贡献可归结为以下几个方面，研究引入 ACT 算法，依靠动作分块预测、Transformer 序列建模、时间集成以及条件变分自编码器（CVAE），有效减轻了高维连续动作的复合误差，增强了动作平滑性以及对多模态示教数据的建模能力。实验基于 Koch v1.1 平台开展，设计并实现了从硬件组装、电机配置、数据采集到策略训练与部署的完整工作流程，验证了低成本硬件在高精度及动态抓取任务中的应用潜力。实验结果证明，在插头精确插入插座任务中，机械臂获得了抓取成功率 86%和插入成功率 66%的结果；在模拟快递流水线动态扫码与分拣任务中，抓取成功率突破 90%，扫描准确率逼近 96%，明显优于传统的 MoveIt 和 RRT-Connect 方法。采用优化数据采集与训练策略的方式，研究大幅降低了数据需求与训练时间，为家庭、实验室这类中小型场景提供了经济又高效的解决办法。与传统方法相比，ACT 算法无需对环境进行复杂建模，仅借助低成本 RGB 摄像头便可实现高水准的性能，训练耗时从数周缩短为数小时，显著减少了时间和经济的成本消耗。

然而，本研究依然存在一定的局限性，ACT 算法对高质量示教数据的依赖程度较高，数据量不足或多样性欠佳，会造成模型在非规则物体或极端姿态情形下的泛化能力不足，特别是在非规则物体、极端姿态的抓取任务中表现不佳。Koch v1.1 平台的硬件限制，如电机扭矩不足和夹爪精度有限，也对其在高力或复杂抓取任务中的应用造成限制。端到端学习框架的可解释性欠佳，不容易精准找出错误的原因，调试效率较低。当前系统依赖单一 RGB 视觉输入，缺少力的反馈或多模态感知途径，可能在复杂物理特性（如透明或柔性物体）或极端环境（如强光干扰）的条件下，性能受到限制。

5.2 研究展望

鉴于本研究的成果以及局限性，未来研究可从以下方面开展，以进一步提升模仿学习在机械臂抓取领域的表现及应用范围。

可将数据获取策略进行优化，减少对高质量示教数据的依赖，采用虚拟现实（VR）或仿真环境（如 Gazebo）生成具有多样性的数据，对复杂场景（如不规则物体堆叠或极端初始姿态）进行模拟，并且结合迁移学习或自监督学习，降低对真实数据的要求量，强化模型的泛化水平，在快递流水线作业里可采用仿真手段生成不同形状物块的数据，增进对不规则物体的适应水平。

强化模型鲁棒性去应对复杂环境挑战，目前系统针对光照变化或透明物体的处理能力有限，未来可借助融合多模态感知（如力反馈与点云数据）提升性能，当进行插头插入任务的时候，依靠力传感器动态调整夹爪的夹持力度，拉动插入成功率上涨；借助更先进的视觉模型（如 Vision Transformer）提高对低对比度物体的识别成效，采用噪声注入的训练方案，对传感器噪声或物体形变进行模拟，加大抗干扰能力。

加入安全约束及可解释性机制以支持实际施行，可在 ACT 框架里嵌入像 MoveIt 这种碰撞检测或路径规划模块，保证机械臂在复杂环境里不发生意外碰撞，在快递流水线任务中，即时探测传送带上的障碍物以规划安全路线，运用注意力机制可视化模型决策过程，提升模型可解释性水平，利于调试与优化。

寻找人机协同和硬件升级来拓展应用范围，结合自然语言处理与手势识别技术，让机械臂懂得人类下达的指令，实现更自然的沟通交互，并完成 Koch v1.1 平台电机和夹爪的升级工作，提高扭矩与精度，适配高力或微小零件操作工作，这些改进可促进模仿学习在柔性制造和物流自动化领域的普遍应用。

本研究达成了 ACT 算法与 Koch v1.1 平台的融合，证明了模仿学习能在低成本硬件上实现高效、可靠抓取策略的可行性，为促进机械臂自动化普及提供了重要参考，未来通过优化数据获取流程、增强泛化能力与鲁棒性优势、加入安全约束条件设置、实现人机协同的局面以及优化算法理论内涵，模仿学习会在更广泛的工业及生活场景里起到更大的效能，为智能机械臂技术的进步注入新的活力。

参考文献

[1] Bohg J, Morales A, Asfour T, et al. Data-driven grasp synthesis—a survey[J]. IEEE Transactions on Robotics, 2013, 30(2): 289-309.

[2] Pomerleau D A. Alvinn: An autonomous land vehicle in a neural network[C]//Advances in Neural Information Processing Systems. 1988, 1: 305-313.

[3] Kober J, Bagnell J A, Peters J. Reinforcement learning in robotics: A survey[J]. The International Journal of Robotics Research, 2013, 32(11): 1238-1274.

[4] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[EB/OL]. arXiv preprint arXiv:2304.13705, 2023 [2025-05-18]. https://arxiv.org/abs/2304.13705.

[5] Argall B D, Chernova S, Veloso M, et al. A survey of robot learning from demonstration[J]. Robotics and Autonomous Systems, 2009, 57(5): 469-483.

[6] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning[C]//Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. JMLR Workshop and Conference Proceedings, 2011: 627-635.

[7] Lee S W, Kang X, Kuo Y L. Diff-dagger: Uncertainty estimation with diffusion policy for robotic manipulation[EB/OL]. arXiv preprint arXiv:2410.14868, 2024 [2025-05-18]. https://arxiv.org/abs/2410.14868.

[8] Finn C, Levine S, Abbeel P. Guided cost learning: Deep inverse optimal control via policy optimization[C]//International Conference on Machine Learning. New York: P MLR, 2016: 49-58.

[9] Ng A Y, Russell S. Algorithms for inverse reinforcement learning[C]//International Conference on Machine Learning. San Francisco: Morgan Kaufmann, 2000, 1(2): 2.

[10] Ziebart B D, Maas A L, Bagnell J A, et al. Maximum entropy inverse reinforcement learning[C]//AAAI Conference on Artificial Intelligence. Chicago: AAAI Press, 2008, 8: 1433–1438.

[11] Ho J, Ermon S. Generative adversarial imitation learning[C]//Advances in Neural Information Processing Systems. 2016, 29: 4565–4573.

[12] Chi C, Xu Z, Feng S, et al. Diffusion policy: Visuomotor policy learning via action diffusion[J]. The International Journal of Robotics Research, 2023, 44(5): 1–25.

[13] Lenz I, Lee H, Saxena A. Deep learning for detecting robotic grasps[J]. The International Journal of Robotics Research, 2015, 34(4-5): 705-724.

[14] Levine S, Pastor P, Krizhevsky A, et al. Learning hand-eye coordination for robotic grasping with deep learning and large-scale data collection[J]. The International Journal of Robotics Research, 2018, 37(4-5): 421-436.

[15] Du Y, Wang W, Wang L. Hierarchical recurrent neural network for skeleton based action recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Boston: IEEE, 2015: 1110-1118.

[16] Hussein A, Gaber M M, Elyan E, et al. Imitation learning: A survey of learning methods[J]. ACM Computing Surveys (CSUR), 2017, 50(2): 1-35.

[17] Graybiel A M. The basal ganglia and chunking of action repertoires[J]. Neurobiology of Learning and Memory, 1998, 70(1-2): 119-136.

[18] Kalashnikov D, Irpan A, Pastor P, et al. Scalable deep reinforcement learning for vision-based robotic manipulation[C]//Conference on Robot Learning. Zürich: PMLR, 2018: 651-673.

[19] Florence P, Lynch C, Zeng A, et al. Implicit behavioral cloning[C]//Conference on Robot Learning. Auckland: PMLR, 2022: 158-168.

[20] Rafailov R, Yu T, Rajeswaran A, et al. Visual adversarial imitation learning using variational models[J]. Advances in Neural Information Processing Systems, 2021, 34: 3016-3028.

[21] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. Long Beach: PMLR, 2019: 6105-6114.

[22] Chen L, Lu K, Rajeswaran A, et al. Decision transformer: Reinforcement learning via sequence modeling[J]. Advances in Neural Information Processing Systems, 2021, 34: 15084-15097.

[23] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30: 5998–6008.

[24] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 213-229.

[25] Micikevicius P, Narang S, Alben J, et al. Mixed precision training[EB/OL]. arXiv preprint arXiv:1710.03740, 2017 [2025-05-18]. https://arxiv.org/abs/1710.03740.

[26] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[EB/OL]. arXiv preprint arXiv:2010.11929, 2020 [2025-05-18]. https://arxiv.org/abs/2010.11929.

[27] Shafiullah N M, Cui Z, Altanzaya A A, et al. Behavior transformers: Cloning k modes with one stone[J]. Advances in Neural Information Processing Systems, 2022, 35: 22955-22968.

[28] Brohan A, Brown N, Carbajal J, et al. Rt-1: Robotics transformer for real-world control at scale[EB/OL]. arXiv preprint arXiv:2212.06817, 2022 [2025-05-18]. https://arxiv.org/abs/2212.06817.

[29] Pari J, Shafiullah N M, Arunachalam S P, et al. The surprising effectiveness of representation learning for visual imitation[EB/OL]. arXiv preprint arXiv:2112.01511, 2021 [2025-05-18]. https://arxiv.org/abs/2112.01511.

[30] Song D, Ek C H, Huebner K, et al. Task-based robot grasp planning using probabilistic inference[J]. IEEE Transactions on Robotics, 2015, 31(3): 546-561.

[31] Mandlekar A, Xu D, Wong J, et al. What matters in learning from offline human demonstrations for robot manipulation[EB/OL]. arXiv preprint arXiv:2108.03298, 2021 [2025-05-18]. https://arxiv.org/abs/2108.03298.

[32] Whitney D E. Mechanical assemblies: Their design, manufacture, and role in product development[M]. Oxford: Oxford University Press, 2004.

[33] Chuang W L, Yeh M H, Yeh Y L. Develop real-time robot control architecture using robot operating system and ethercat[J]. Actuators. MDPI, 2021, 10(7): 141.

[34] Chen I M. Theory and applications of modular reconfigurable robotic systems[D]. Pasadena: California Institute of Technology, 1994.

[35] Li Z, Li S, Francis A, et al. A novel calibration system for robot arm via an open dataset and a learning perspective[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2022, 69(12): 5169-5173.

[36] Bergamini L, Sposato M, Pellicciari M, et al. Deep learning-based method for vision-guided robotic grasping of unknown objects[J]. Advanced Engineering Informatics, 2020, 44: 101052.

[37] Gao J, Xie A, Xiao T, et al. Efficient data collection for robotic manipulation via compositional generalization[EB/OL]. arXiv preprint arXiv:2403.05110, 2024 [2025-05-18]. https://arxiv.org/abs/2403.05110.

[38] Robinette M F, Manseur R. Robot-Draw, an Internet-based visualization tool for robotics education[J]. IEEE Transactions on Education, 2001, 44(1): 29-34.

[39] Laskin M, Lee K, Stooke A, et al. Reinforcement learning with augmented data[J]. Advances in Neural Information Processing Systems, 2020, 33: 19884-19895.

[40] Quigley M, Conley K, Gerkey B, et al. ROS: an open-source Robot Operating System[C]//ICRA Workshop on Open Source Software. Kobe: IEEE, 2009, 3(3.2): 5.

[41] Corke P I, Jachimczyk W, Pillat R. Robotics, vision and control: fundamental algorithms in MATLAB[M]. Berlin: Springer, 2011.

致谢

窗外的月光悄然爬上书页，为这段青葱岁月落下最后的注脚。当键盘敲击声最终停驻在初夏的晚风里，四年的光阴忽然在指缝间流淌成河，倒映着图书馆的晨曦、实验室的星辰，以及无数个与自我对话的深夜。

承蒙恩师李智教授悉心栽培，学生方得窥学术门径。犹记初探课题时，好似雾中行舟，是您以春风化雨般的指导，将晦涩的理论拆解成可触的星光。您总能在数据迷宫中指明方向，在实验瓶颈时拨云见日，那些"再想想"的鼓励，"试试看"的期许，终让稚嫩的想法破茧新生，既带着穿云裂石的严谨，亦怀揣海纳百川的包容，这样的风范将永远引领我的求知之路。

感谢肖冬教授如同暗夜提灯人，为我照亮思维的盲区。感谢曹轲、吕舒宁、徐泓智学长，实验室里的那些日日夜夜，是毕业季最温暖的星光。感谢杨松泽、张天驹、安基盛三位室友，四载春秋里我们共享过泡面的香气，也见证过彼此为课程设计熬红的双眼，那些插科打诨的日常终将酿成岁月的美酒。

课堂上，先生们以书为桨，带我们横渡知识之海；实验室里，导师们执规为剑，为我们斩开迷雾重峦。同窗少年们的身影散落在图书馆的各个角落，书写声惊醒了沉睡的典籍，草稿纸记载着灵感的乍现。那些为小组作业争得面红耳赤的午后，为课程答辩反复排练的黄昏，都是青春最生动的注脚。

特别要将这薄薄的纸页献给故乡的灯火。父母从未说过"你要成才"的重话，但他们欲言又止的关切，每次归家时茶几上摆放的水果，都是二十年来最绵长的守护。最后，谨以这篇尚显稚拙的论文，献给这个让我们在课堂上仍能触摸真理的时代，献给所有在特殊时期守护知识火种的先行者。

晨光已在天际晕染，这趟四载的求知之旅，与其说是抵达某个终点，不如说是收到无数双手递来的船桨，那些智慧的火种，善意的光芒，都将在未来岁月里继续生长。此去经年，少年将负笈远行，而东大校园的梧桐年轮里，永远镌刻着我们的黄金时代。

谨以青涩文字，铭记这一程山水相逢。

